Сравнительное исследование численных и нейросетевых методов моделирования динамики конкурирующих популяций

Коннова Т.

2027-01-01

Содержание

Введение **4**

1. Математическое моделирование популяционной динамики и методы решения **6**
1.1. Классические модели популяционной динамики 6
1.1.1. Истоки математической экологии 6
1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры 7
1.1.3. Режимы конкуренции 7
1.2. Пространственные модели: реакция--диффузия 8
1.2.1. От ОДУ к уравнениям в частных производных 8
1.2.2. Диффузионная модель конкуренции 9
1.3. Численные методы решения 10
1.3.1. Методы решения ОДУ 10
1.3.2. Методы решения УЧП 11
1.4. Физически-информированные нейронные сети (PINN) 12
1.4.1. Предпосылки и основная идея 12
1.4.2. Обзор развития метода 13
1.4.3. Проблемы и ограничения PINN 13
1.4.4. Применение PINN к модели конкуренции 14
1.5. Программные средства решения 15
1.5.1. Библиотека NeuralPDE.jl 15
Выводы по главе 15

2. Программная реализация и вычислительные эксперименты **16**
2.1. Выбор инструментальных средств 16
2.2. Параметры вычислительных экспериментов 17
2.3. Положения равновесия и их устойчивость 17
2.4. Устойчивое сосуществование 18
2.5. Конкурентное вытеснение 18
2.6. Бистабильность 18
2.7. Решение ОДУ методом PINN в Pluto 25
2.7.1. Схема обучения 25

2.7.2. Независимая проверка точности 25
Выводы по этапу ОДУ 31

Список литературы **32**

Введение

Математические модели популяционной динамики связывают изменение численности видов со скоростью размножения, ограниченностью ресурсов и межвидовыми взаимодействиями. В работе рассматривается конкуренция двух популяций за общий ресурс: сначала без учёта пространства, затем с диффузионным переносом.

Классические подходы к решению систем дифференциальных уравнений, описывающих популяционную динамику, основаны на численных методах (семейство Рунге--Кутты, конечные разности). Для системы обыкновенных дифференциальных уравнений используется адаптивный метод Рунге--Кутты `Tsit5`. Пространственная модель требует дискретизации не только времени, но и координаты, поэтому число неизвестных определяется размером пространственной сетки.

В качестве второго способа решения используются физически-информированные нейронные сети (Physics-Informed Neural Networks, PINN) [1]. Дифференциальное уравнение входит в функцию потерь через невязку, вычисляемую в коллокационных точках. PINN не строит конечно-разностный шаблон, но всё равно использует дискретный набор точек для обучения.

Цель работы --- провести сравнительное исследование классических численных и нейросетевых методов решения математических моделей динамики конкурирующих популяций, включая модели с пространственной диффузией.

Задачи:

1. Исследовать математическую модель межвидовой конкуренции Лотки--Вольтерры (система ОДУ) и её расширение с учётом пространственной диффузии (система УЧП).
2. Реализовать численное решение моделей классическими методами на языке Julia с использованием библиотеки DifferentialEquations.jl.

3. Реализовать решение тех же моделей с помощью PINN на основе библиотеки NeuralPDE.jl.
4. Провести сравнительный анализ точности, вычислительных затрат и устойчивости обоих подходов.
5. Исследовать влияние параметров нейросетевой архитектуры на качество решения.

Объект исследования --- математические модели конкурирующих популяций.

Предмет исследования --- численные и нейросетевые методы решения систем обыкновенных дифференциальных уравнений и уравнений в частных производных, описывающих динамику конкурирующих популяций.

Сравнение методов проводится при одинаковых параметрах модели и начальных условиях. Оцениваются средняя и максимальная абсолютные ошибки относительно классического решения, время вычислений, сохранение неотрицательности численностей и воспроизводимость результата при разных инициализациях нейронной сети.

1. Математическое моделирование популяционной динамики и методы решения

1.1. Классические модели популяционной динамики

1.1.1. Истоки математической экологии

Математическое описание динамики биологических популяций берёт начало в работах А. Лотки [2] и В. Вольтерры [3], которые независимо друг от друга в 1920-х годах предложили системы обыкновенных дифференциальных уравнений для описания взаимодействия двух видов. Модель «хищник--жертва» Лотки--Вольтерры стала одной из ранних математических формализаций экологических взаимодействий и послужила основой для последующих моделей взаимодействующих популяций.

Классическая модель хищник--жертва имеет вид:

$$\begin{cases} \dfrac{dx}{dt} = \alpha x - \beta xy, \\ \dfrac{dy}{dt} = -\gamma y + \delta xy, \end{cases} \tag{1.1}$$

где $x(t)$ --- численность жертв, $y(t)$ --- численность хищников, $\alpha, \beta, \gamma, \delta > 0$ --- параметры модели. Решения этой системы обладают периодическим характером, а фазовые траектории образуют замкнутые кривые вокруг внутренней неподвижной точки. Система допускает первый интеграл $\alpha \ln y - \beta y + \gamma \ln x - \delta x = C$, что позволяет верифицировать численные решения [4].

В монографии А. Д. Базыкина [5] систематизированы бифуркационные явления в нелинейных моделях взаимодействующих популяций. Ю. М. Свирежев и Д. О. Логофет [6] исследовали вопросы устойчивости биологических сообществ на основе качественной теории дифференциальных уравнений. Фундаментальная двухтомная монография Дж. Мюррея [7,8] является одним из наиболее полных изложений методов математической биологии, включая пространственные модели.

1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры

В отличие от модели «хищник--жертва», где один вид потребляет другой, модель межвидовой конкуренции описывает ситуацию, когда два вида борются за общий ограниченный ресурс. Каждый вид подчиняется логистическому закону роста, а присутствие конкурента снижает доступность ресурса. Модель записывается в виде системы ОДУ [4,7]:

$$\begin{cases} \dfrac{dN_1}{dt} = r_1 N_1 \left(1 - \dfrac{N_1 + \alpha_{12} N_2}{K_1}\right), \\ \dfrac{dN_2}{dt} = r_2 N_2 \left(1 - \dfrac{N_2 + \alpha_{21} N_1}{K_2}\right), \end{cases} \tag{1.2}$$

где $N_i(t)$ --- численность i-го вида, r_i --- скорость естественного прироста, K_i --- ёмкость среды (максимальная численность при отсутствии конкурента), α_{12} и α_{21} --- коэффициенты межвидовой конкуренции.

Коэффициент α_{12} показывает, насколько одна особь вида 2 эквивалентна особи вида 1 в потреблении ресурса. При $\alpha_{12} = 0$ виды не конкурируют, при $\alpha_{12} = 1$ одна особь конкурента эквивалентна одной собственной особи.

1.1.3. Режимы конкуренции

Система (Уравнение 1.2) имеет четыре стационарные точки: $E_0 = (0, 0)$, $E_1 = (K_1, 0)$, $E_2 = (0, K_2)$ и внутреннюю точку сосуществования

$$E^* = \left(\frac{K_1 - \alpha_{12} K_2}{1 - \alpha_{12}\alpha_{21}},\ \frac{K_2 - \alpha_{21} K_1}{1 - \alpha_{12}\alpha_{21}}\right),$$

которая существует (обе координаты положительны) лишь при определённых соотношениях параметров. Анализ устойчивости этих точек приводит к классификации трёх качественно различных режимов динамики [5,7]:

1. **Устойчивое сосуществование** ($\alpha_{12} < K_1/K_2$ и $\alpha_{21} < K_2/K_1$). Межвидовая конкуренция слабее внутривидовой. Точка E^* существует и является устойчивым узлом; оба вида сохраняют ненулевую численность. При $K_1 = K_2$ условия принимают вид $\alpha_{12} < 1$ и $\alpha_{21} < 1$; неравенство $\alpha_{12}\alpha_{21} < 1$ является следствием этих условий, но не заменяет их.

2. **Конкурентное вытеснение** ($\alpha_{12} > K_1/K_2$ и $\alpha_{21} < K_2/K_1$, или наоборот). Один из видов вытесняет другой независимо от начальных условий. Устойчивой является одна из граничных точек (E_1 или E_2). Данный результат известен как *принцип конкурентного исключения Гаузе*.

3. **Бистабильность** ($\alpha_{12} > K_1/K_2$ и $\alpha_{21} > K_2/K_1$). Межвидовая конкуренция сильнее внутривидовой. Точки E_1 и E_2 обе устойчивы, а E^* --- седловая точка. Исход зависит от начальных условий: сепаратриса седловой точки разделяет области притяжения двух устойчивых состояний. При $K_1 = K_2$ требуются одновременно $\alpha_{12} > 1$ и $\alpha_{21} > 1$; одного условия $\alpha_{12}\alpha_{21} > 1$ недостаточно.

Классификация режимов следует из анализа существования и устойчивости стационарных точек [4,7]. В отличие от консервативной модели хищник--жертва (Уравнение 1.1), траектории рассматриваемой модели конкуренции в типичных режимах стремятся к стационарным состояниям. Поэтому первый интеграл модели хищник--жертва нельзя использовать для проверки решения системы конкуренции.

1.2. Пространственные модели: реакция--диффузия

1.2.1. От ОДУ к уравнениям в частных производных

Классические модели вида (Уравнение 1.2) предполагают пространственно однородное распределение популяций. В реальных экосистемах особи перемещаются в пространстве, и плотность популяции $N_i(t, x)$ зависит не

только от времени t, но и от пространственной координаты x. Переход к пространственным моделям осуществляется добавлением диффузионных членов, описывающих случайное (броуновское) движение особей [8,9].

Механизм диффузии формализуется законом Фика: поток особей пропорционален градиенту плотности и направлен из областей высокой концентрации в области низкой. Для одномерного случая это приводит к диффузионному оператору $D\partial^2 N/\partial x^2$, где вторая производная по пространству характеризует кривизну профиля плотности: при локальном максиме ($\partial^2 N/\partial x^2 < 0$) особи расходятся, при локальном минимуме ($\partial^2 N/\partial x^2 > 0$) --- стекаются.

Пионерские работы в области реакционно-диффузионных уравнений принадлежат Р. Фишеру [10], предложившему уравнение распространения выгодного гена:

$$\frac{\partial u}{\partial t} = D\frac{\partial^2 u}{\partial x^2} + ru(1-u), \tag{1.3}$$

являющееся простейшим примером уравнения реакции--диффузии, допускающим решения в виде бегущих волн. А. Тьюринг [11] показал, что в некоторых многокомпонентных системах реакция--диффузия однородное стационарное состояние может потерять устойчивость после добавления диффузии. Однако этот результат нельзя автоматически переносить на любую экологическую модель. Для рассматриваемой ниже системы конкуренции с постоянными коэффициентами и обычной собственной диффузией наличие тьюринговской неустойчивости должно проверяться отдельно; различие коэффициентов D_1 и D_2 само по себе не гарантирует образование паттернов.

1.2.2. Диффузионная модель конкуренции

После добавления пространственного переноса модель (Уравнение 1.2) принимает вид системы реакции--диффузии:

$$\begin{cases} \dfrac{\partial N_1}{\partial t} = D_1\dfrac{\partial^2 N_1}{\partial x^2} + r_1 N_1\left(1 - \dfrac{N_1 + \alpha_{12}N_2}{K_1}\right), \\ \dfrac{\partial N_2}{\partial t} = D_2\dfrac{\partial^2 N_2}{\partial x^2} + r_2 N_2\left(1 - \dfrac{N_2 + \alpha_{21}N_1}{K_2}\right), \end{cases} \tag{1.4}$$

где $D_i > 0$ --- коэффициенты диффузии, характеризующие интенсивность пространственного перемещения особей i-го вида. Слагаемые $D_i\partial^2 N_i/\partial x^2$

описывают перемещение особей из областей высокой концентрации в области низкой концентрации (закон Фика).

Уравнения (Уравнение 1.4) дополняются начальными условиями $N_i(x,0) = N_{i,0}(x)$ и граничными условиями. Наиболее часто используются условия Неймана (нулевой поток на границе), моделирующие замкнутую область обитания [9]:

$$\left.\frac{\partial N_i}{\partial x}\right|_{x=0} = \left.\frac{\partial N_i}{\partial x}\right|_{x=L} = 0, \quad i = 1, 2.$$

Монография Кантрелла и Коснера [9] содержит систематическое изложение теории пространственной экологии на основе уравнений реакции-диффузии, включая вопросы существования и устойчивости стационарных решений. Устойчивые пространственно неоднородные состояния в моделях конкуренции зависят от постановки задачи: гетерогенности среды, граничных условий, структуры диффузии и параметров взаимодействия [12].

При пространственно однородных начальных условиях и нулевом потоке система (Уравнение 1.4) воспроизводит соответствующую ОДУ-модель. Неоднородные начальные данные добавляют переходные пространственные процессы. В частности, при различных начальных распределениях $N_{1,0}(x)$ и $N_{2,0}(x)$ (например, один вид локализован слева, другой --- справа) динамика включает фазу диффузионного проникновения видов на территорию конкурента, что качественно отличается от ODE-случая. В вычислительной части такие сценарии используются для сравнения численного и нейросетевого решений.

1.3. Численные методы решения

1.3.1. Методы решения ОДУ

Для численного решения систем ОДУ вида (Уравнение 1.2) широко применяются методы семейства Рунге--Кутты [13]. Метод Цитораса (`Tsit5`) относится к явным методам Рунге--Кутты 5(4) порядка. Встроенная формула четвёртого порядка служит для оценки локальной ошибки и выбора следующего шага. Реализация `Tsit5` входит в экосистему DifferentialEquations.jl [14] для языка Julia [15].

Для жёстких систем применяются неявные методы (Розенброка, BDF), также доступные в DifferentialEquations.jl. Экосистема DifferentialEquations.jl предоставляет унифицированный интерфейс для явных и неявных методов, средства автоматического выбора алгоритма и анализа чувствительности [14].

1.3.2. Методы решения УЧП

Классическим подходом к решению систем реакции--диффузии (Уравнение 1.4) является метод конечных разностей [16]. Пространственная производная аппроксимируется на равномерной сетке:

$$\frac{\partial^2 N}{\partial x^2} \approx \frac{N_{j-1} - 2N_j + N_{j+1}}{(\Delta x)^2},$$

после чего система УЧП сводится к системе ОДУ (метод прямых, method of lines), которая решается стандартными методами.

На сетке с n узлами по каждой координате число пространственных неизвестных пропорционально n^d, где d --- размерность пространства. Поэтому переход от одномерной области к двумерной или трёхмерной увеличивает объём системы. Для явной аппроксимации диффузии шаг по времени дополнительно ограничен условием устойчивости вида $\Delta t \leq C(\Delta x)^2/D$; уменьшение Δx требует уменьшать и Δt. Неявные схемы снимают ограничение на шаг, но требуют решения систем линейных уравнений на каждом временном слое.

Альтернативой конечным разностям являются конечные элементы и спектральные методы, однако их реализация существенно сложнее. Метод прямых, сводящий систему УЧП к большой системе ОДУ, позволяет использовать адаптивные солверы ОДУ (включая Tsit5) и является основным подходом, реализованным в DifferentialEquations.jl [14].

1.4. Физически-информированные нейронные сети (PINN)

1.4.1. Предпосылки и основная идея

Возможность аппроксимации произвольных непрерывных функций нейронными сетями обоснована теоремой об универсальной аппроксимации [17]: для любой непрерывной функции и заданной точности $\varepsilon > 0$ существует нейронная сеть с одним скрытым слоем, аппроксимирующая эту функцию с точностью ε.

В методе PINN дифференциальное уравнение включается в функцию потерь нейронной сети [1]. Нейросеть $N(x; w)$ с параметрами (весами) w обучается аппроксимировать неизвестное решение $u(x)$ дифференциального уравнения $F(u(x); \lambda) = 0$ путём минимизации составной функции потерь:

$$L(w) = L_r + L_{ic} + L_{bc}, \tag{1.5}$$

где:

- $L_r = \sum_i \|F(N(x_i; w); \lambda)\|^2$ --- невязка дифференциального уравнения в коллокационных точках x_i (residual loss);
- $L_{ic} = \sum_j \|N(x_j; w) - u_0(x_j)\|^2$ --- отклонение от начальных условий;
- $L_{bc} = \sum_k \|B(N(x_k; w))\|^2$ --- отклонение от граничных условий.

Производные нейросети N по входным переменным вычисляются с помощью автоматического дифференцирования, а не конечно-разностной аппроксимации. При этом точность итогового решения определяется не только вычислением производных, но и архитектурой сети, набором коллокационных точек и результатом оптимизации.

Теорема об универсальной аппроксимации обосновывает выразительность нейронной сети, но не гарантирует успешной оптимизации PINN, малой ошибки решения или выполнения начальных и граничных условий.

1.4.2. Обзор развития метода

Обзорная статья Karniadakis и соавторов [18] в Nature Reviews Physics систематизировала направление «physics-informed machine learning» и выделила PINN как один из центральных инструментов. Масштабный обзор Cuomo и соавторов [19] проанализировал более 200 работ по PINN, классифицировал архитектуры, стратегии обучения и области применения.

Chen и соавторы [20] предложили концепцию Neural ODE --- представление динамической системы как непрерывного аналога глубокой нейросети, что привело к созданию нового класса моделей на стыке машинного обучения и дифференциальных уравнений. Rackauckas и соавторы [21] развили эту идею в концепцию Universal Differential Equations (UDE), где часть дифференциального оператора заменяется нейросетью, обучаемой по данным.

1.4.3. Проблемы и ограничения PINN

Обучение PINN сводится к невыпуклой задаче оптимизации, поэтому малая невязка на обучающих точках сама по себе не гарантирует малую ошибку решения во всей области.

Wang, Teng и Perdikaris [22] исследовали проблемы градиентных потоков при обучении PINN и показали, что разные компоненты функции потерь (Уравнение 1.5) могут конфликтовать, приводя к дисбалансу обучения. Авторы предложили адаптивное взвешивание компонент loss-функции для повышения сходимости.

Krishnapriyan и соавторы [23] систематически изучили возможные режимы отказа PINN и показали, что для систем с колебательной динамикой и длинными временными интервалами PINN испытывают трудности с аппроксимацией.

Jagtap, Kawaguchi и Karniadakis [24] предложили адаптивные функции активации, ускоряющие сходимость PINN.

Rohrhofer и соавторы [25] исследовали компромисс между точностью выполнения уравнений и соответствием данным, построив парето-фронт для различных конфигураций PINN.

1.4.4. Применение PINN к модели конкуренции

Для системы конкуренции нейронная сеть должна одновременно аппроксимировать две неотрицательные функции численности. В задаче с диффузией к двум невязкам уравнений добавляются начальные и граничные условия. Их вклады в функцию потерь могут иметь разные масштабы, поэтому качество решения проверяется не только по значению loss-функции, но и прямым сравнением с классическим численным методом.

В реализованной ОДУ-схеме неотрицательность обеспечивается заменой

$$N_1 = K_1 e^{z_1}, \qquad N_2 = K_2 e^{z_2}. \tag{1.6}$$

После подстановки в систему (Уравнение 1.2) получаются уравнения для выходов нейронной сети $z_1(t)$ и $z_2(t)$:

$$\begin{aligned} \frac{dz_1}{dt} &= r_1 \left(1 - e^{z_1} - \alpha_{12}\frac{K_2}{K_1} e^{z_2}\right), \\ \frac{dz_2}{dt} &= r_2 \left(1 - e^{z_2} - \alpha_{21}\frac{K_1}{K_2} e^{z_1}\right). \end{aligned} \tag{1.7}$$

Для набора обучающих моментов t_j невязки имеют вид

$$\begin{aligned} R_1(t_j; w) &= \frac{d\hat{z}_1}{dt}(t_j; w) - r_1 \left(1 - e^{\hat{z}_1(t_j;w)} - \alpha_{12}\frac{K_2}{K_1} e^{\hat{z}_2(t_j;w)}\right), \\ R_2(t_j; w) &= \frac{d\hat{z}_2}{dt}(t_j; w) - r_2 \left(1 - e^{\hat{z}_2(t_j;w)} - \alpha_{21}\frac{K_1}{K_2} e^{\hat{z}_1(t_j;w)}\right). \end{aligned} \tag{1.8}$$

Численная residual loss на фиксированной сетке выражается как среднее квадратов этих невязок:

$$L_r(w) = \frac{1}{M}\sum_{j=1}^{M} \left(R_1(t_j; w)^2 + R_2(t_j; w)^2\right). \tag{1.9}$$

В алгоритме `NNODE` начальное условие включается в пробную аппроксимацию решения, поэтому оно выполняется конструктивно [26]. Производные $d\hat{z}_i/dt$ вычисляются автоматическим дифференцированием. Значение loss

характеризует выполнение уравнений в обучающих точках, но не равно ошибке относительно `Tsit5`. Поэтому после обучения отдельно вычисляются максимальная нормированная ошибка и относительная L_2-ошибка на общей проверочной сетке.

Сначала это сравнение выполняется для ОДУ на трёх режимах динамики: сосуществовании, вытеснении и бистабильности. Затем тот же порядок применяется к пространственной модели. Такой переход позволяет отдельно проверить ошибку нейросетевой аппроксимации и влияние пространственных производных.

1.5. Программные средства решения

1.5.1. Библиотека NeuralPDE.jl

Библиотека NeuralPDE.jl [27] входит в экосистему SciML и предоставляет высокоуровневый интерфейс для решения ОДУ и УЧП с помощью PINN на языке Julia. Для систем ОДУ алгоритм `NNODE` работает со стандартным объектом `ODEProblem` и функцией правой части, записанной во вневекторизованной форме `f(u,p,t)` [26]. Для систем УЧП `PhysicsInformedNN` преобразует символьное описание `PDESystem`, построенное средствами ModelingToolkit.jl, в задачу оптимизации [28]. Архитектура нейронной сети в обоих случаях может задаваться с помощью Lux.jl.

Выводы по главе

1. Аналитическая классификация модели конкуренции задаёт три контрольных режима и ожидаемые стационарные состояния для проверки программной реализации.
2. Для ОДУ эталонное решение строится методом `Tsit5`; для системы реакции--диффузии используется пространственная дискретизация с последующим интегрированием по времени.
3. Результат PINN необходимо сравнивать с эталонным решением по ошибке во всей расчётной области. Это особенно существенно для длинных временных интервалов и составной функции потерь [22,23].

2. Программная реализация и вычислительные эксперименты

В главе представлена программная реализация классической модели межвидовой конкуренции и вычислительный эксперимент PINN для системы обыкновенных дифференциальных уравнений. Пространственная модель будет исследована на следующих этапах работы.

2.1. Выбор инструментальных средств

Расчёты выполнены на языке Julia. Для интегрирования системы используется библиотека OrdinaryDiffEq.jl и явный адаптивный метод Рунге--Кутты Цитораса `Tsit5` порядка 5(4). PINN реализована алгоритмом `NNODE` библиотеки NeuralPDE.jl, архитектура сети задаётся средствами Lux.jl, а оптимизация выполняется методом BFGS из OptimizationOptimJL.jl. Интерактивный вычислительный протокол оформлен как Pluto-блокнот. Графики построены средствами Plots.jl.

Классический эксперимент находится в `code/ode/competition_model.jl`, а воспроизводимый Pluto-блокнот --- в `code/pluto/competition_pinn.jl`. Для повторного запуска закреплены Julia 1.13.3, Pluto 1.1.0, NeuralPDE 7.5.0, Lux 1.31.5, OrdinaryDiffEq 7.8.1, OptimizationOptimJL 0.4.23 и Plots 1.41.7. Точные зависимости сохранены в файлах `Project.toml` и `Manifest.toml`.

Вычислительный эксперимент включает:

1. автоматическую классификацию режима по двум пороговым неравенствам;
2. вычисление аналитических положений равновесия;
3. оценку устойчивости равновесий по собственным значениям матрицы Якоби;

4. численное решение для нескольких начальных условий;
5. проверку неотрицательности решения и сходимости к теоретически ожидаемому равновесию;
6. построение временных графиков и фазовых портретов.

2.2. Параметры вычислительных экспериментов

Для трёх режимов использованы наборы параметров, приведённые в таблице Таблица 2.1. Скорости роста во всех экспериментах равны $r_1 = r_2 = 1$.

Таблица 2.1.: Параметры трёх режимов конкуренции

Режим	K_1	K_2	α_{12}	α_{21}	Ожидаемый предел
Сосуществование	100	100	0,5	0,3	E^*
Вытеснение	100	80	0,4	1,5	E_1
Бистабильность	100	100	1,5	1,5	E_1 или E_2

Условия режимов проверяются отдельно для каждого коэффициента. Для сосуществования необходимы неравенства $\alpha_{12} < K_1/K_2$ и $\alpha_{21} < K_2/K_1$. Для бистабильности направления обоих неравенств меняются на противоположные. Условие только на произведение $\alpha_{12}\alpha_{21}$ не используется как достаточный критерий.

2.3. Положения равновесия и их устойчивость

Матрица Якоби системы вычисляется в каждой аналитической стационарной точке. Точка считается устойчивой, если действительные части обоих собственных значений отрицательны. Если собственные значения имеют действительные части разных знаков, равновесие является седловым.

Таблица 2.2.: Результаты анализа устойчивости равновесий

Режим	Устойчивые равновесия	Неустойчивые и седловые точки
Сосуществование	$E^* = (58{,}8235;\ 82{,}3529)$	E_0 неустойчиво; E_1 и E_2 --- седла
Вытеснение	$E_1 = (100;\ 0)$	E_0 неустойчиво; $E_2 = (0;\ 80)$ --- седло
Бистабильность	$E_1 = (100;\ 0)$ и $E_2 = (0;\ 100)$	E_0 неустойчиво; $E^* = (40;\ 40)$ --- седло

2.4. Устойчивое сосуществование

Для всех четырёх проверенных начальных условий численное решение сходится к одной внутренней точке $E^* = (58{,}8235;\ 82{,}3529)$. Максимальное расстояние между конечным состоянием при $t = 30$ и аналитическим равновесием среди рассмотренных траекторий не превышает $7{,}3 \cdot 10^{-4}$.

Фазовый портрет на рисунке Рисунок 2.2 показывает, что траектории из различных частей положительного квадранта сходятся к одной устойчивой внутренней точке.

2.5. Конкурентное вытеснение

При $\alpha_{12} = 0{,}4$ и $\alpha_{21} = 1{,}5$ устойчивой является граничная точка $E_1 = (100;\ 0)$. Во всех четырёх экспериментах, включая начальное условие $N_1(0) = 20$, $N_2(0) = 70$, первый вид вытесняет второй. Численный результат совпадает с теоретическим прогнозом и не зависит от выбранного положительного начального условия.

2.6. Бистабильность

В симметричном случае $K_1 = K_2 = 100$ и $\alpha_{12} = \alpha_{21} = 1{,}5$ граничные точки E_1 и E_2 устойчивы, а внутренняя точка $E^* = (40;\ 40)$ является

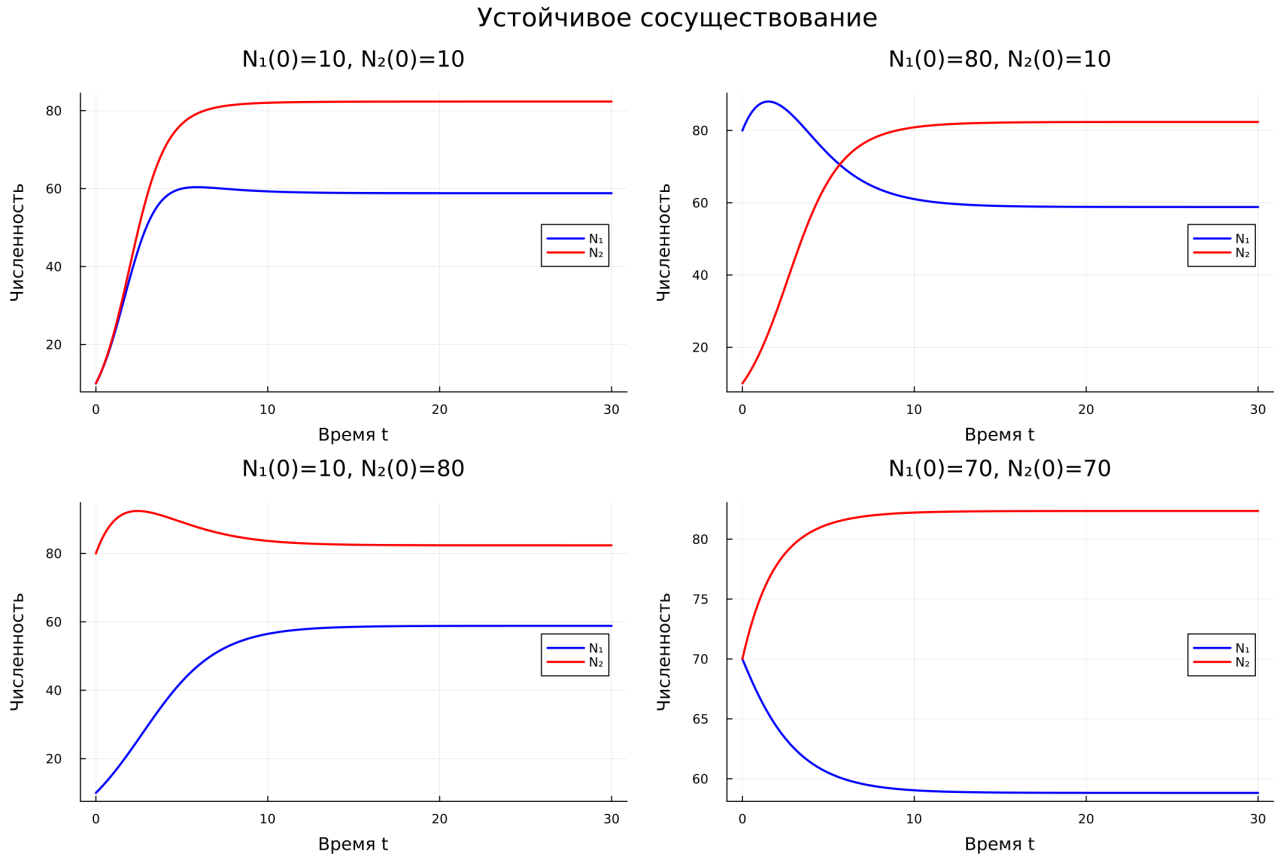


Рис. 2.1.: Динамика численностей в режиме устойчивого сосуществования

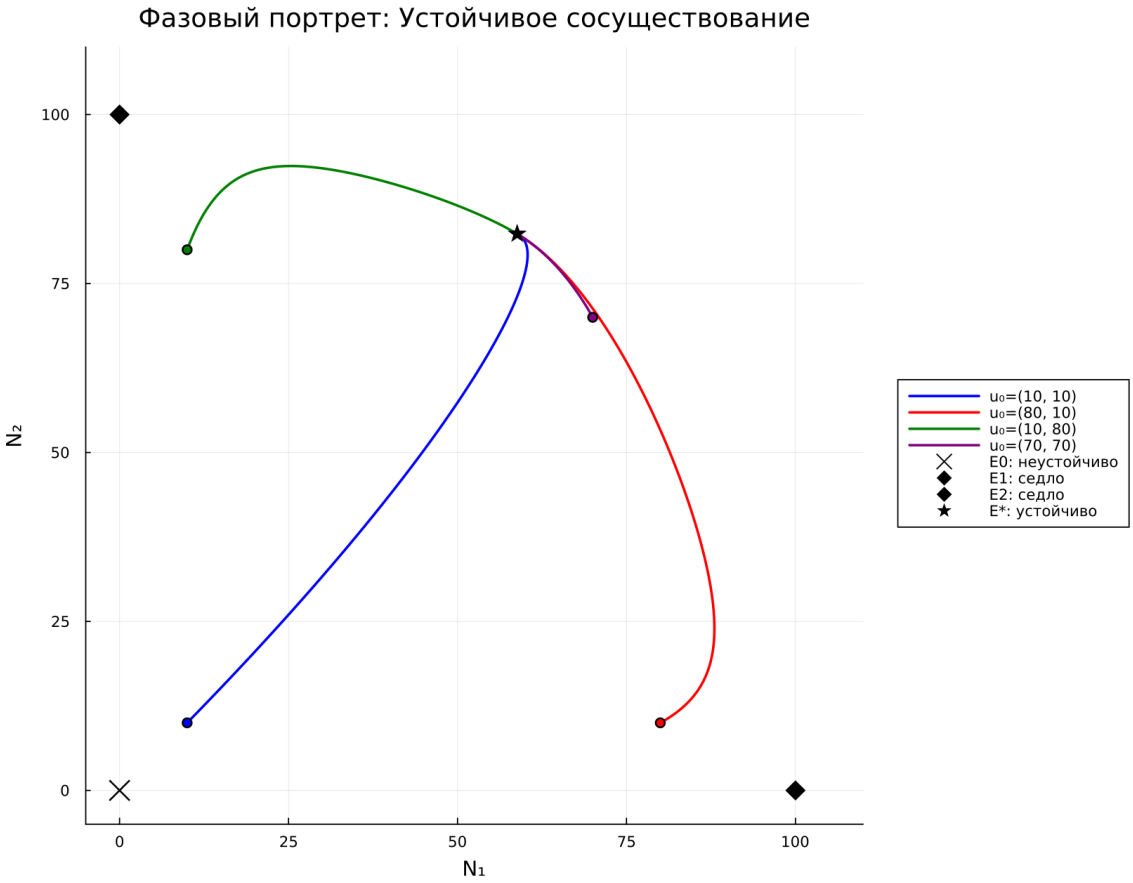


Рис. 2.2.: Фазовый портрет режима устойчивого сосуществования

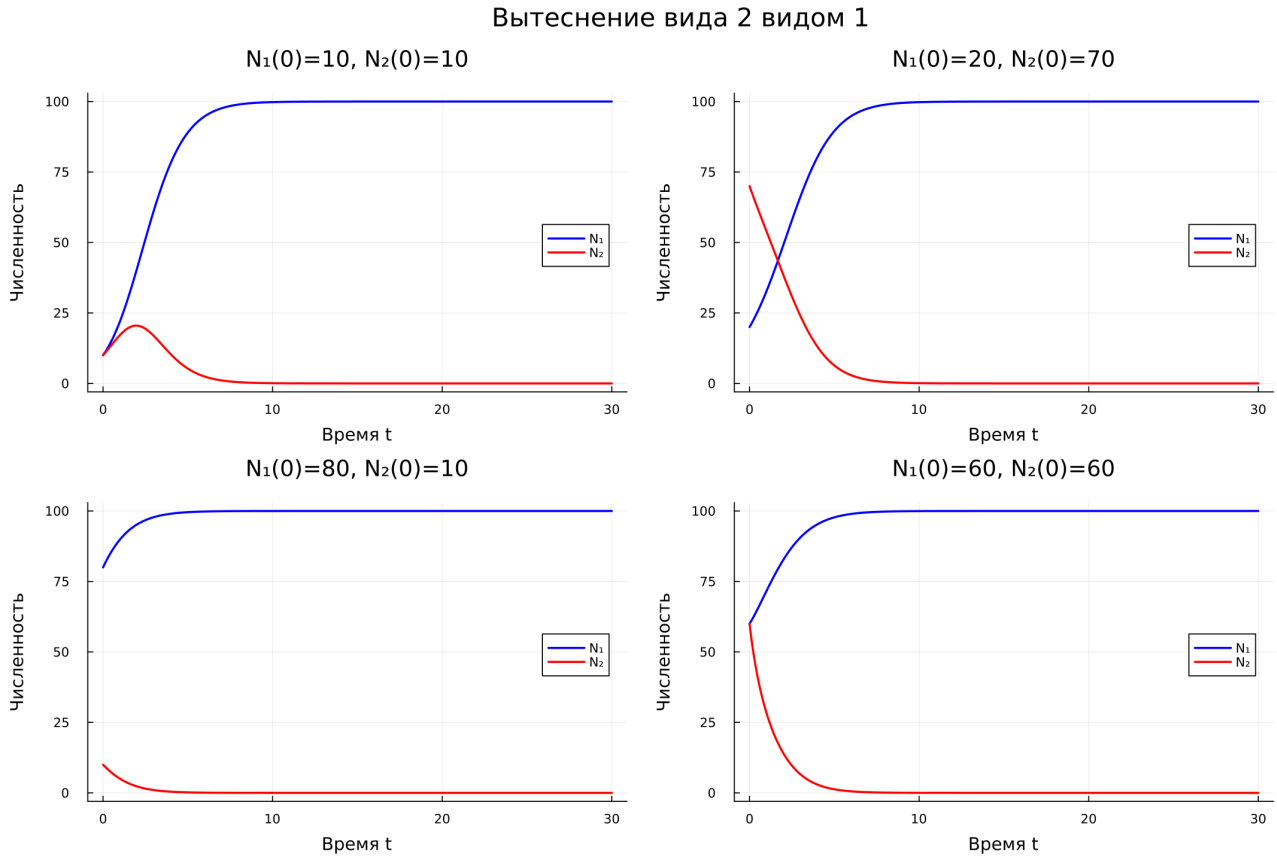


Рис. 2.3.: Динамика численностей в режиме вытеснения

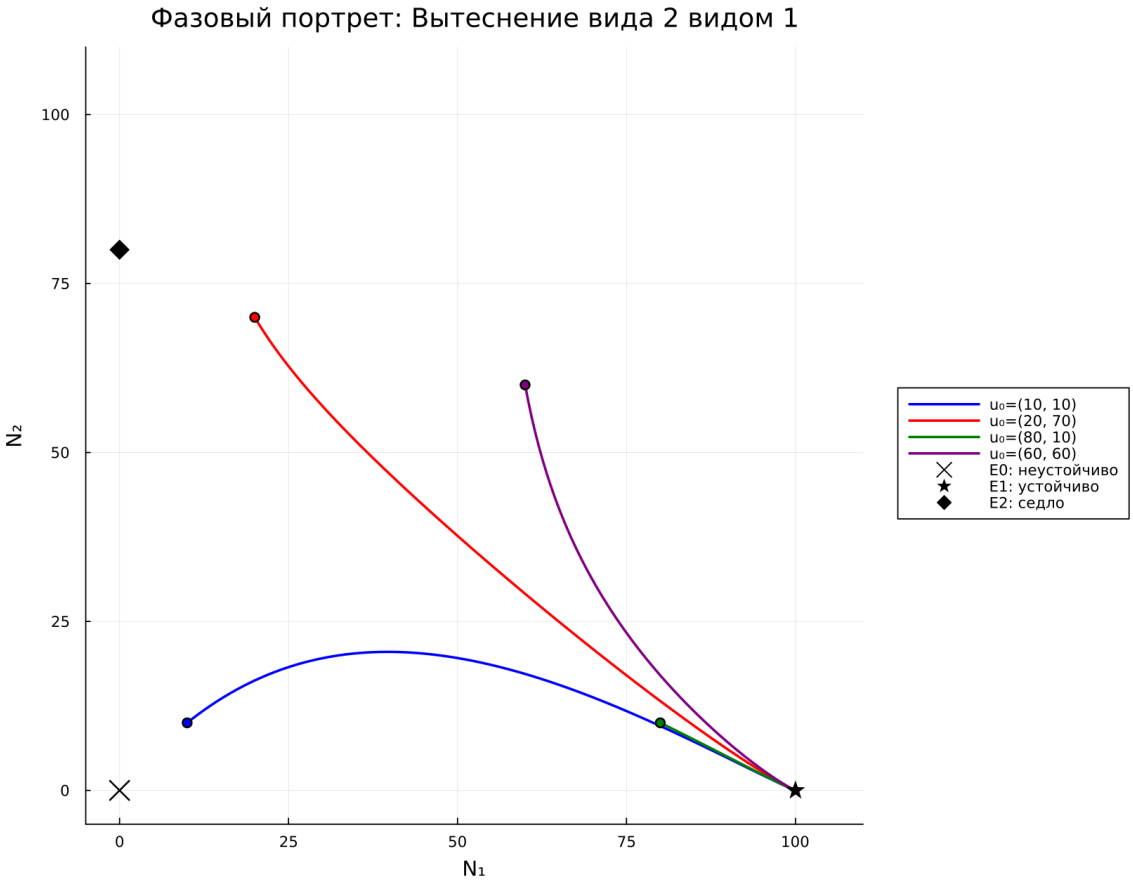


Рис. 2.4.: Фазовый портрет режима вытеснения

седлом. Начальные условия $(80; 20)$ и $(65; 35)$ приводят к равновесию E_1, тогда как условия $(20; 80)$ и $(35; 65)$ приводят к E_2.

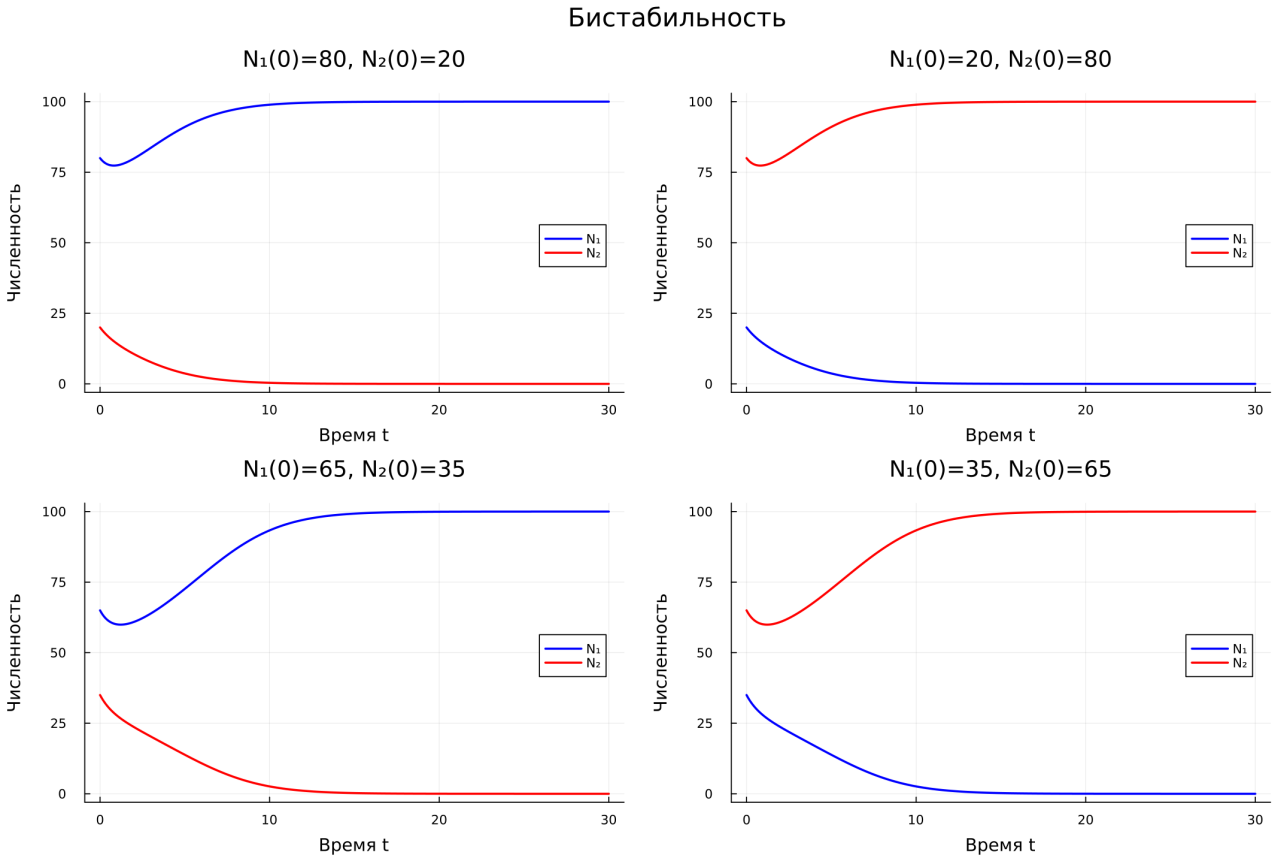


Рис. 2.5.: Динамика численностей в режиме бистабильности

В выбранном симметричном примере сепаратрисой является прямая $N_1 = N_2$. Она разделяет области притяжения двух устойчивых граничных равновесий. Это частный симметричный случай: для произвольных параметров сепаратриса не обязана совпадать с прямой равных численностей.

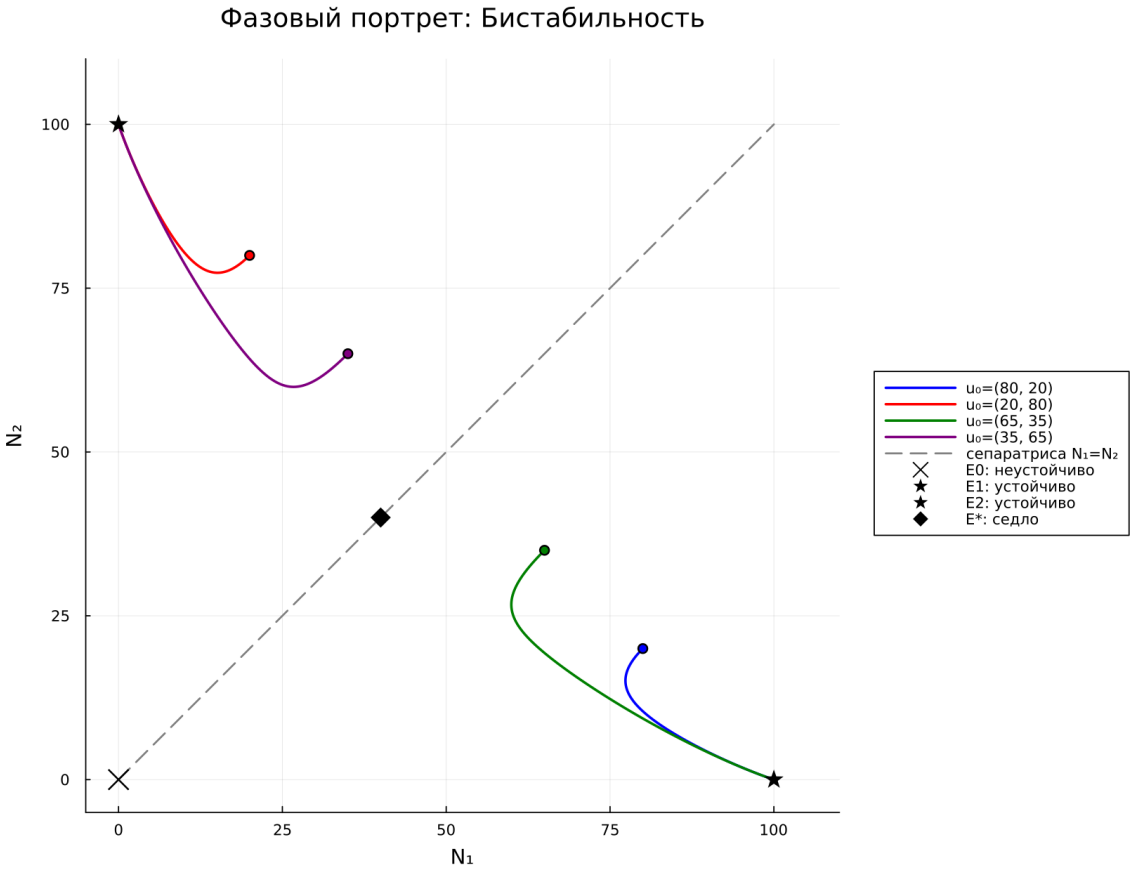


Рис. 2.6.: Фазовый портрет режима бистабильности

2.7. Решение ОДУ методом PINN в Pluto

2.7.1. Схема обучения

Для нейросетевого решения использован алгоритм `NNODE` библиотеки NeuralPDE.jl [26]. Первоначальная попытка обучать одну сеть сразу на всём интервале давала неудовлетворительное приближение на его дальней части. Поэтому в итоговом эксперименте интервал $0 \leq t \leq 20$ разбит на десять последовательных окон длиной 2. Конечное состояние каждого окна становится начальным условием следующего.

Неотрицательность численностей обеспечивается логарифмической заменой (Уравнение 1.6), а loss вычисляется по невязкам (Уравнение 1.8)--(Уравнение 1.9). Использована полносвязная сеть 1--16--16--2 с функцией активации `tanh` и фиксированной инициализацией `seed = 42`. На каждом окне применяется BFGS, стратегия `GridTraining(0.05)` и не более 600 итераций.

Если первая схема не удовлетворяет критерию точности, программой предусмотрена повторная попытка: окно сокращается до 1, фиксированная сетка заменяется адаптивным интегрированием невязки, а лимит увеличивается до 1000 итераций. В выполненном эксперименте все пять траекторий прошли первую схему, поэтому резервный вариант фактически не запускался.

2.7.2. Независимая проверка точности

При обучении значения `Tsit5` не входят в функцию потерь. После обучения PINN сравнивается с эталонной траекторией на сетке с шагом 0,05. Эталон `Tsit5` дополнительно сверяется с решением `Vern9`; максимальное нормированное различие двух численных методов должно быть меньше 10^{-7}.

Используются две метрики:

$$\varepsilon_{\max} = \max_{i,j} \frac{|N_i^{\mathrm{PINN}}(t_j) - N_i^{\mathrm{Tsit5}}(t_j)|}{K_i}, \tag{2.1}$$

$$\varepsilon_{L_2} = \frac{\|N^{\mathrm{PINN}} - N^{\mathrm{Tsit5}}\|_2}{\|N^{\mathrm{Tsit5}}\|_2}. \tag{2.2}$$

Критерий принятия результата имеет вид $\varepsilon_{\max} < 0{,}01$ при конечных положительных значениях обеих численностей. В Таблица 2.3 приведены результаты контрольного запуска 10 ноября 2026 г.

Таблица 2.3.: Ошибки PINN относительно Tsit5 на интервале $[0; 20]$

Исход и начальное условие	$\varepsilon_{\max}$	ε_{L_2}
Победа вида 1; $(50; 30)$	$7{,}456 \cdot 10^{-6}$	$2{,}508 \cdot 10^{-6}$
Победа вида 2; $(50; 30)$	$6{,}873 \cdot 10^{-6}$	$2{,}820 \cdot 10^{-6}$
Сосуществование; $(50; 30)$	$9{,}839 \cdot 10^{-6}$	$4{,}182 \cdot 10^{-6}$
Бистабильность; $(80; 20)$	$2{,}477 \cdot 10^{-5}$	$5{,}424 \cdot 10^{-6}$
Бистабильность; $(20; 80)$	$8{,}745 \cdot 10^{-6}$	$2{,}823 \cdot 10^{-6}$

Наибольшая относительная L_2-ошибка равна $5{,}424 \cdot 10^{-6}$, или приблизительно 0,000542%. Наибольшая точечная ошибка, нормированная на ёмкость среды, равна $2{,}477 \cdot 10^{-5}$; при $K_i = 100$ это соответствует расхождению около 0,00248 единицы численности. Поэтому на графике общего масштаба сплошные линии `Tsit5` и пунктирные линии PINN практически накладываются.

Времена обучения пяти траекторий составили соответственно 76,2; 47,3; 47,1; 50,6 и 43,6 с. Все пять результатов получены первой схемой; повторное обучение не потребовалось.

Для количественного чтения результата построен отдельный график абсолютной ошибки. Значение по вертикальной оси показывает $|N_i^{\mathrm{PINN}} - N_i^{\mathrm{Tsit5}}|$ в исходных единицах численности, а не значение loss.

На увеличенном фрагменте `Tsit5` показан синей линией, PINN --- пурпурным пунктиром с маркерами. Нижняя панель содержит знаковую разность: положительное значение означает завышение прогноза PINN, отрицательное --- занижение.

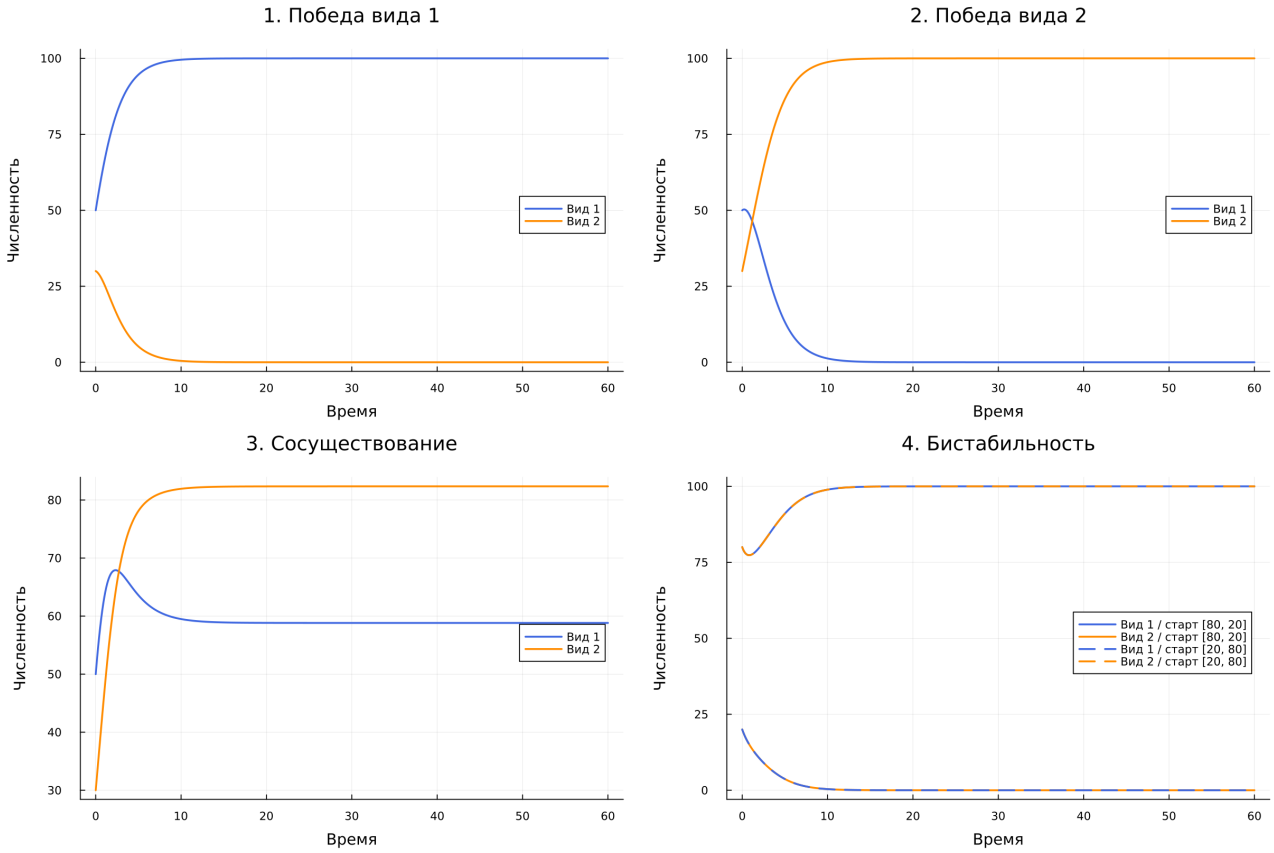


Рис. 2.7.: Четыре исхода модели конкуренции по численному решению

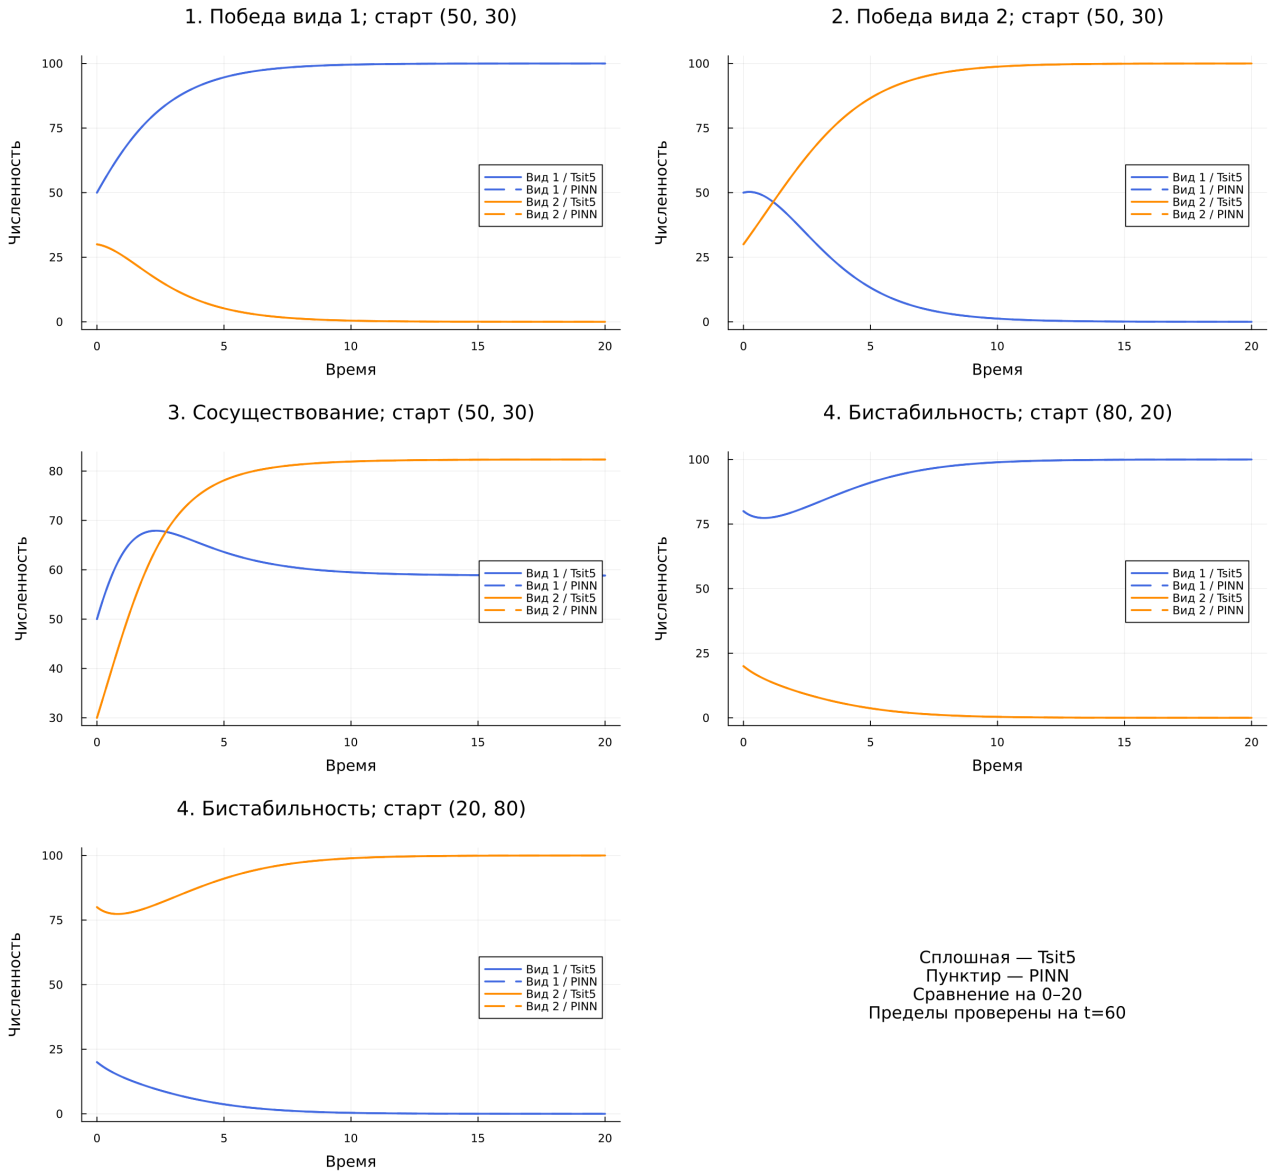


Рис. 2.8.: Сравнение PINN и Tsit5 для пяти траекторий

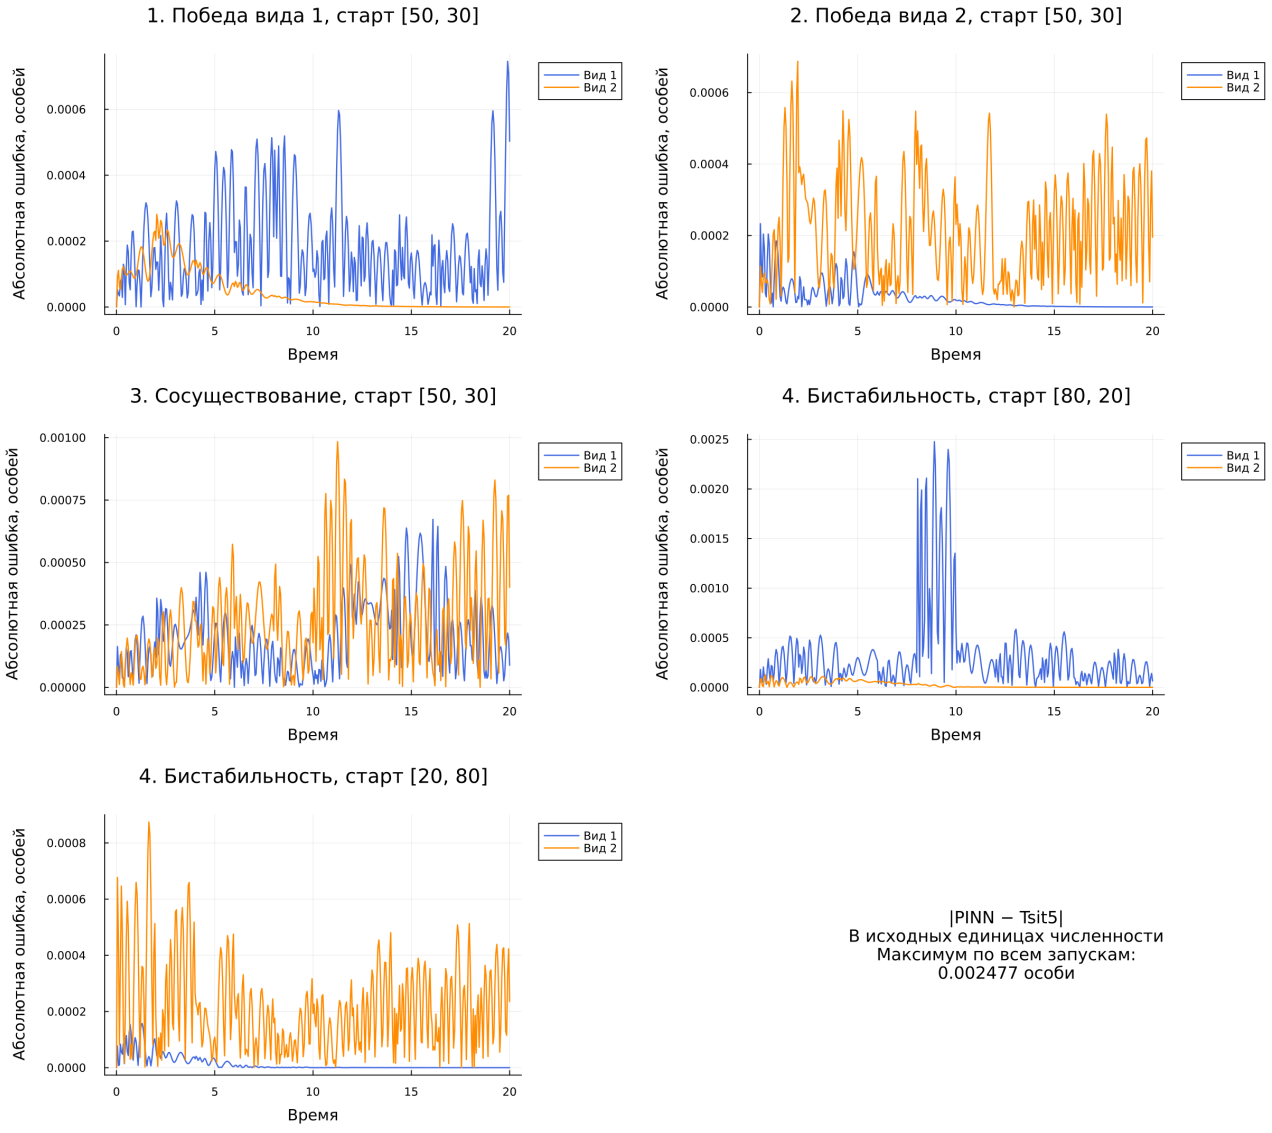


Рис. 2.9.: Абсолютная ошибка PINN относительно Tsit5

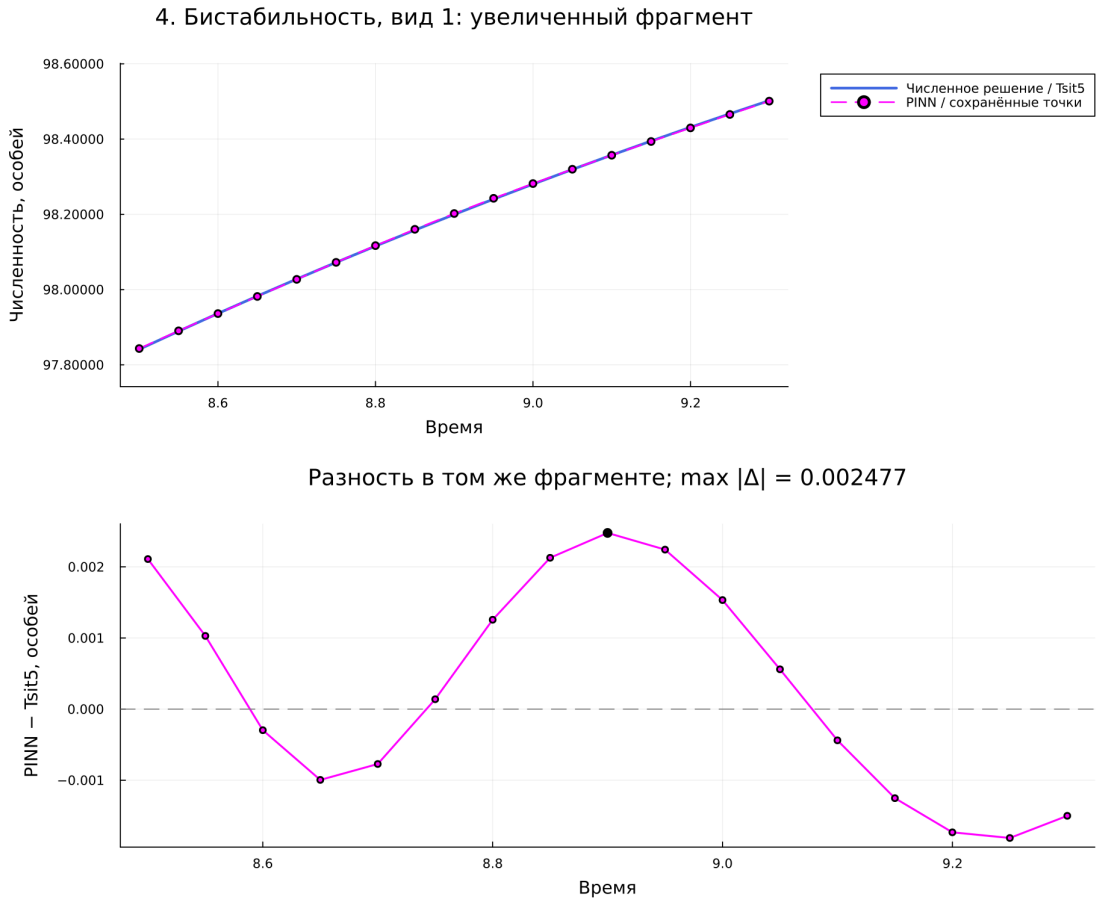


Рис. 2.10.: Увеличенный фрагмент с максимальным расхождением

Приведённые времена относятся к одному последовательному запуску на конкретном компьютере и не являются аппаратно-независимым бенчмарком. Первый сценарий включает дополнительные накладные расходы первого обращения к нейросетевому решателю. Кроме того, полный интервал пока проверен для одной инициализации сети (`seed = 42`); для оценки устойчивости PINN необходимо повторить эксперимент с несколькими значениями `seed`.

Выводы по этапу ОДУ

Решения `Tsit5` для трёх математических режимов сохраняют неотрицательность численностей и сходятся к равновесиям, найденным при аналитическом исследовании. Для двух направлений вытеснения, сосуществования и двух исходов бистабильности оконная PINN на интервале $[0; 20]$ прошла установленный критерий точности без повторного обучения. Максимальная относительная L_2-ошибка в контрольном запуске составила $5{,}424 \cdot 10^{-6}$. Следующий этап проверки должен включать несколько случайных инициализаций и единый протокол измерения времени после прогрева среды.

Список литературы

1. Raissi M., Perdikaris P., Karniadakis G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations // Journal of Computational Physics. 2019. Т. 378. С. 686--707.
2. Lotka A. J. Elements of Physical Biology. Baltimore: Williams; Wilkins, 1925. С. 460.
3. Вольтерра В. Математическая теория борьбы за существование. Москва: Наука, 1976. С. 286.
4. Братусь А. С., Новожилов А. С., Платонов А. П. Динамические системы и модели биологии. Москва: Физматлит, 2010. С. 400.
5. Базыкин А. Д. Нелинейная динамика взаимодействующих популяций. Ижевск: Институт компьютерных исследований, 2003. С. 368.
6. Свирежев Ю. М., Логофет Д. О. Устойчивость биологических сообществ. Москва: Наука, 1978. С. 352.
7. Murray J. D. Mathematical Biology I: An Introduction. 3rd изд. New York: Springer, 2002.
8. Murray J. D. Mathematical Biology II: Spatial Models and Biomedical Applications. 3rd изд. New York: Springer, 2003.
9. Cantrell R. S., Cosner C. Spatial Ecology via Reaction-Diffusion Equations. Chichester: Wiley, 2003. С. 432.
10. Fisher R. A. The wave of advance of advantageous genes // Annals of Eugenics. 1937. Т. 7, No. 4. С. 355--369.
11. Turing A. M. The chemical basis of morphogenesis // Philosophical Transactions of the Royal Society of London B. 1952. Т. 237. С. 37--72.
12. Cosner C., Lazer A. C. Stable Coexistence States in the Volterra--Lotka Competition Model with Diffusion // SIAM Journal on Applied Mathematics. 1984. Т. 44, No. 6. С. 1112--1132.
13. Hairer E., Nørsett S. P., Wanner G. Solving Ordinary Differential Equations I: Nonstiff Problems. 2nd изд. Berlin: Springer, 1993.

14. Rackauckas C., Nie Q. DifferentialEquations.jl -- A Performant and Feature-Rich Ecosystem for Solving Differential Equations in Julia // Journal of Open Research Software. 2017. Т. 5, No. 1. С. 15--25.
15. Bezanson J. и др. Julia: A Fresh Approach to Numerical Computing // SIAM Review. 2017. Т. 59, No. 1. С. 65--98.
16. Самарский А. А., Гулин А. В. Численные методы. Москва: Наука, 1989. С. 432.
17. Hornik K. Approximation capabilities of multilayer feedforward networks // Neural Networks. 1991. Т. 4, No. 2. С. 251--257.
18. Karniadakis G. E. и др. Physics-informed machine learning // Nature Reviews Physics. 2021. Т. 3, No. 6. С. 422--440.
19. Cuomo S. и др. Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next // Journal of Scientific Computing. 2022. Т. 92, No. 88.
20. Chen R. T. Q. и др. Neural Ordinary Differential Equations // Advances in Neural Information Processing Systems. 2018. Т. 31.
21. Rackauckas C. и др. Universal Differential Equations for Scientific Machine Learning // arXiv preprint. 2020.
22. Wang S., Teng Y., Perdikaris P. Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks // SIAM Journal on Scientific Computing. 2021. Т. 43, No. 5. С. A3055--A3081.
23. Krishnapriyan A. S. и др. Characterizing possible failure modes in physics-informed neural networks // Advances in Neural Information Processing Systems. 2021. Т. 34. С. 26548--26560.
24. Jagtap A. D., Kawaguchi K., Karniadakis G. E. Adaptive activation functions accelerate convergence in deep and physics-informed neural networks // Journal of Computational Physics. 2020. Т. 404. С. 109136.
25. Rohrhofer F. M. и др. On the Pareto Front of Physics-Informed Neural Networks // IEEE Access. 2023. Т. 11. С. 85613--85633.
26. SciML. ODE-Specialized Physics-Informed Neural Network Solver [Электронный ресурс]. 2026. URL: https://docs.sciml.ai/NeuralPDE/stable/manual/ode/ (дата обращения: 08.11.2026).
27. Zubov K. и др. NeuralPDE: Automating Physics-Informed Neural Networks (PINNs) with Error Approximations // arXiv preprint. 2021.
28. SciML. PhysicsInformedNN Discretizer for PDESystems [Электронный ресурс]. 2026. URL: https://docs.sciml.ai/NeuralPDE/stable/manual/pinns/ (дата обращения: 08.11.2026).