Сравнительное исследование численных и нейросетевых методов моделирования динамики конкурирующих популяций

Коннова Т.

2027-01-01

Содержание

Введение **3**

1. Математическое моделирование популяционной динамики и методы решения **5**

1.1. Классические модели популяционной динамики 5
1.1.1. Истоки математической экологии 5
1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры 6
1.1.3. Режимы конкуренции 6
1.2. Пространственные модели: реакция--диффузия 7
1.2.1. От ОДУ к уравнениям в частных производных 7
1.2.2. Диффузионная модель конкуренции 8
1.3. Численные методы решения 8
1.3.1. Методы решения ОДУ 8
1.3.2. Методы решения УЧП 9
1.4. Физически-информированные нейронные сети (PINN) 9
1.4.1. Предпосылки и основная идея 9
1.4.2. Обзор развития метода 10
1.4.3. Проблемы и ограничения PINN 11
1.4.4. PINN для экологических моделей 11
1.5. Программные средства решения 11
1.5.1. Библиотека NeuralPDE.jl 11
1.5.2. Опыт применения в группе РУДН 12
Выводы по главе 12

Введение

Математическое моделирование динамики биологических популяций является одной из классических задач математической биологии, имеющей фундаментальное значение для понимания механизмов взаимодействия видов в экосистемах. Модели межвидовой конкуренции, описывающие борьбу двух или более видов за общий ресурс, находят применение в экологии, эпидемиологии, а также в задачах управления биоресурсами.

Классические подходы к решению систем дифференциальных уравнений, описывающих популяционную динамику, основаны на численных методах (семейство Рунге--Кутты, конечные разности). Эти методы хорошо изучены и обладают доказанной сходимостью, однако при переходе к пространственным моделям (уравнениям в частных производных) их вычислительная сложность существенно возрастает.

В последние годы активно развивается альтернативный подход --- физически-информированные нейронные сети (Physics-Informed Neural Networks, PINN), предложенные Raissi и соавторами в 2019 году. PINN встраивают дифференциальные уравнения непосредственно в функцию потерь нейронной сети, что позволяет решать прямые и обратные задачи без построения вычислительной сетки.

Цель работы --- провести сравнительное исследование классических численных и нейросетевых методов решения математических моделей динамики конкурирующих популяций, включая модели с пространственной диффузией.

Задачи:

1. Исследовать математическую модель межвидовой конкуренции Лотки--Вольтерры (система ОДУ) и её расширение с учётом пространственной диффузии (система УЧП).
2. Реализовать численное решение моделей классическими методами на языке Julia с использованием библиотеки DifferentialEquations.jl.

3. Реализовать решение тех же моделей с помощью PINN на основе библиотеки NeuralPDE.jl.
4. Провести сравнительный анализ точности, вычислительных затрат и устойчивости обоих подходов.
5. Исследовать влияние параметров нейросетевой архитектуры на качество решения.

Объект исследования --- математические модели конкурирующих популяций.

Предмет исследования --- численные и нейросетевые методы решения систем обыкновенных и дифференциальных уравнений в частных производных, описывающих динамику конкурирующих популяций.

1. Математическое моделирование популяционной динамики и методы решения

1.1. Классические модели популяционной динамики

1.1.1. Истоки математической экологии

Математическое описание динамики биологических популяций берёт начало в работах А. Лотки [1] и В. Вольтерры [2], которые независимо друг от друга в 1920-х годах предложили системы обыкновенных дифференциальных уравнений для описания взаимодействия двух видов. Модель «хищник--жертва» Лотки--Вольтерры стала первой математической формализацией экологических взаимодействий и до сих пор остаётся отправной точкой для построения более сложных моделей.

Классическая модель хищник--жертва имеет вид:

$$\begin{cases} \dfrac{dx}{dt} = \alpha x - \beta xy, \\ \dfrac{dy}{dt} = -\gamma y + \delta xy, \end{cases} \tag{1.1}$$

где $x(t)$ --- численность жертв, $y(t)$ --- численность хищников, $\alpha, \beta, \gamma, \delta > 0$ --- параметры модели. Решения этой системы обладают периодическим характером, а фазовые траектории образуют замкнутые кривые вокруг внутренней неподвижной точки. Система допускает первый интеграл $\alpha \ln y - \beta y + \gamma \ln x - \delta x = C$, что позволяет верифицировать численные решения [3].

Значительный вклад в развитие теории нелинейных моделей популяционной динамики внесли работы А. Д. Базыкина [4], в которых систематизированы бифуркационные явления в моделях взаимодействующих популяций. Ю. М. Свирежев и Д. О. Логофет [5] исследовали вопросы устойчивости биологических сообществ на основе качественной теории дифференциальных уравнений. Фундаментальная двухтомная монография Дж. Мюррея [6,7] является одним из наиболее полных изложений методов математической биологии, включая пространственные модели.

1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры

В отличие от модели «хищник--жертва», где один вид потребляет другой, модель межвидовой конкуренции описывает ситуацию, когда два вида борются за общий ограниченный ресурс. Каждый вид подчиняется логистическому закону роста, а присутствие конкурента снижает доступность ресурса. Модель записывается в виде системы ОДУ [3,6]:

$$\begin{cases} \dfrac{dN_1}{dt} = r_1 N_1 \left(1 - \dfrac{N_1 + \alpha_{12} N_2}{K_1}\right), \\ \dfrac{dN_2}{dt} = r_2 N_2 \left(1 - \dfrac{N_2 + \alpha_{21} N_1}{K_2}\right), \end{cases} \tag{1.2}$$

где $N_i(t)$ --- численность i-го вида, r_i --- скорость естественного прироста, K_i --- ёмкость среды (максимальная численность при отсутствии конкурента), α_{12} и α_{21} --- коэффициенты межвидовой конкуренции.

Коэффициент α_{12} показывает, насколько одна особь вида 2 эквивалентна особи вида 1 в потреблении ресурса. При $\alpha_{12} = 0$ виды не конкурируют, при $\alpha_{12} = 1$ одна особь конкурента эквивалентна одной собственной особи.

1.1.3. Режимы конкуренции

Анализ стационарных точек системы (Уравнение 1.2) и их устойчивости приводит к классификации трёх качественно различных режимов динамики [4,6]:

1. **Устойчивое сосуществование** ($\alpha_{12}\alpha_{21} < 1$). Межвидовая конкуренция слабее внутривидовой. Система имеет устойчивую внутреннюю неподвижную точку, в которой оба вида сохраняют ненулевую численность.

2. **Конкурентное вытеснение** ($\alpha_{12} > K_1/K_2$ или $\alpha_{21} > K_2/K_1$ при определённых соотношениях). Один из видов вытесняет другой независимо от начальных условий. Данный результат известен как *принцип конкурентного исключения Гаузе*.

3. **Бистабильность** ($\alpha_{12}\alpha_{21} > 1$). Межвидовая конкуренция сильнее внутривидовой. Исход зависит от начальных условий: в зависимости от начальных численностей выживает один или другой вид.

Эти режимы имеют ясную экологическую интерпретацию и подтверждаются экспериментальными данными [3].

1.2. Пространственные модели: реакция--диффузия

1.2.1. От ОДУ к уравнениям в частных производных

Классические модели вида (Уравнение 1.2) предполагают пространственно однородное распределение популяций. В реальных экосистемах особи перемещаются в пространстве, и плотность популяции зависит не только от времени t, но и от пространственной координаты x. Переход к пространственным моделям осуществляется добавлением диффузионных членов, описывающих случайное движение особей [7,8].

Пионерские работы в области реакционно-диффузионных уравнений принадлежат Р. Фишеру [9], предложившему уравнение распространения выгодного гена, и А. Тьюрингу [10], показавшему возможность спонтанного образования пространственных паттернов из однородного состояния.

1.2.2. Диффузионная модель конкуренции

Диффузионное расширение модели (Уравнение 1.2) представляет собой систему уравнений реакции--диффузии:

$$\begin{cases} \dfrac{\partial N_1}{\partial t} = D_1 \dfrac{\partial^2 N_1}{\partial x^2} + r_1 N_1 \left(1 - \dfrac{N_1 + \alpha_{12} N_2}{K_1}\right), \\ \dfrac{\partial N_2}{\partial t} = D_2 \dfrac{\partial^2 N_2}{\partial x^2} + r_2 N_2 \left(1 - \dfrac{N_2 + \alpha_{21} N_1}{K_2}\right), \end{cases} \tag{1.3}$$

где $D_i > 0$ --- коэффициенты диффузии, характеризующие интенсивность пространственного перемещения особей i-го вида. Слагаемые $D_i \partial^2 N_i / \partial x^2$ описывают перемещение особей из областей высокой концентрации в области низкой концентрации (закон Фика).

Уравнения (Уравнение 1.3) дополняются начальными условиями $N_i(x, 0) = N_{i,0}(x)$ и граничными условиями. Наиболее часто используются условия Неймана (нулевой поток на границе), моделирующие замкнутую область обитания [8]:

$$\left.\frac{\partial N_i}{\partial x}\right|_{x=0} = \left.\frac{\partial N_i}{\partial x}\right|_{x=L} = 0, \quad i = 1, 2.$$

Монография Кантрелла и Коснера [8] содержит систематическое изложение теории пространственной экологии на основе уравнений реакции-диффузии, включая вопросы существования стационарных решений и формирования пространственных паттернов. Мюррей [7] подробно рассматривает условия возникновения диффузионной неустойчивости (неустойчивость Тьюринга) в экологических моделях.

1.3. Численные методы решения

1.3.1. Методы решения ОДУ

Для численного решения систем ОДУ вида (Уравнение 1.2) широко применяются методы семейства Рунге--Кутты [11]. В частности, метод Цитораса (Tsit5) --- явный метод Рунге--Кутты 5(4) порядка с адаптивным шагом --- является одним из наиболее эффективных для нежёстких задач. Он

реализован в экосистеме DifferentialEquations.jl [12] на языке Julia [13] и используется как метод по умолчанию.

Для жёстких систем применяются неявные методы (Розенброка, BDF), также доступные в DifferentialEquations.jl. Экосистема DifferentialEquations.jl предоставляет унифицированный интерфейс для более чем 300 солверов, автоматический выбор метода и средства анализа чувствительности [12].

1.3.2. Методы решения УЧП

Классическим подходом к решению систем реакции--диффузии (Уравнение 1.3) является метод конечных разностей [14]. Пространственная производная аппроксимируется на равномерной сетке:

$$\frac{\partial^2 N}{\partial x^2} \approx \frac{N_{j-1} - 2N_j + N_{j+1}}{(\Delta x)^2},$$

после чего система УЧП сводится к системе ОДУ (метод прямых, method of lines), которая решается стандартными методами.

Данный подход прост в реализации и хорошо изучен, однако при переходе к задачам высокой размерности (двумерное и трёхмерное пространство) количество узлов сетки растёт экспоненциально, что приводит к значительным вычислительным затратам.

1.4. Физически-информированные нейронные сети (PINN)

1.4.1. Предпосылки и основная идея

Возможность аппроксимации произвольных непрерывных функций нейронными сетями обоснована теоремой об универсальной аппроксимации [15]: для любой непрерывной функции и заданной точности $\varepsilon > 0$ существует нейронная сеть с одним скрытым слоем, аппроксимирующая эту функцию с точностью ε.

Ключевой идеей, заложенной в работах Raissi, Perdikaris и Karniadakis [16,17], является встраивание дифференциальных уравнений непосредственно в функцию потерь (loss function) нейронной сети. Нейросеть $N(x; w)$ с параметрами (весами) w обучается аппроксимировать неизвестное решение $u(x)$ дифференциального уравнения $F(u(x); \lambda) = 0$ путём минимизации составной функции потерь:

$$L(w) = L_r + L_{ic} + L_{bc}, \tag{1.4}$$

где:

- $L_r = \sum_i \|F(N(x_i; w); \lambda)\|^2$ --- невязка дифференциального уравнения в коллокационных точках x_i (residual loss);
- $L_{ic} = \sum_j \|N(x_j; w) - u_0(x_j)\|^2$ --- отклонение от начальных условий;
- $L_{bc} = \sum_k \|B(N(x_k; w))\|^2$ --- отклонение от граничных условий.

Производные нейросети N по входным переменным вычисляются точно с помощью автоматического дифференцирования, а не конечных разностей, что обеспечивает высокую точность вычисления невязки L_r.

1.4.2. Обзор развития метода

Обзорная статья Karniadakis и соавторов [18] в Nature Reviews Physics систематизировала направление «physics-informed machine learning» и выделила PINN как один из центральных инструментов. Масштабный обзор Cuomo и соавторов [19] проанализировал более 200 работ по PINN, классифицировал архитектуры, стратегии обучения и области применения.

Chen и соавторы [20] предложили концепцию Neural ODE --- представление динамической системы как непрерывного аналога глубокой нейросети, что привело к созданию нового класса моделей на стыке машинного обучения и дифференциальных уравнений. Rackauckas и соавторы [21] развили эту идею в концепцию Universal Differential Equations (UDE), где часть дифференциального оператора заменяется нейросетью, обучаемой по данным.

1.4.3. Проблемы и ограничения PINN

Несмотря на элегантность подхода, PINN имеют ряд существенных ограничений.

Wang, Teng и Perdikaris [22] исследовали проблемы градиентных потоков при обучении PINN и показали, что разные компоненты функции потерь (Уравнение 1.4) могут конфликтовать, приводя к дисбалансу обучения. Авторы предложили адаптивное взвешивание компонент loss-функции для повышения сходимости.

Krishnapriyan и соавторы [23] систематически изучили возможные режимы отказа PINN и показали, что для систем с колебательной динамикой и длинными временными интервалами PINN испытывают трудности с аппроксимацией.

Jagtap, Kawaguchi и Karniadakis [24] предложили адаптивные функции активации, ускоряющие сходимость PINN.

Rohrhofer и соавторы [25] исследовали компромисс между точностью выполнения уравнений и соответствием данным, построив парето-фронт для различных конфигураций PINN.

1.4.4. PINN для экологических моделей

Применение PINN к задачам экологического моделирования является активно развивающимся направлением.

Banerjee и Gupta [26] продемонстрировали восстановление параметров модели Лотки--Вольтерры из зашумлённых данных с помощью PINN, показав применимость метода к обратным задачам экологической динамики.

1.5. Программные средства решения

1.5.1. Библиотека NeuralPDE.jl

Библиотека NeuralPDE.jl [27] входит в экосистему SciML и предоставляет высокоуровневый интерфейс для решения ОДУ и УЧП с помощью PINN на языке Julia. Для систем ОДУ используется алгоритм `NNODE`, для систем

УЧП --- `PhysicsInformedNN`. Дифференциальные уравнения задаются в символьной форме с помощью пакета ModelingToolkit.jl, а архитектура нейросети определяется через Lux.jl.

Библиотека DeepXDE [28], реализованная на Python, является альтернативным инструментом с аналогичной функциональностью. Сравнительный анализ этих библиотек представляет самостоятельный интерес, однако выходит за рамки настоящей работы.

1.5.2. Опыт применения в группе РУДН

Коллективом кафедры теории вероятности и кибербезопасности РУДН накоплен значительный опыт применения NeuralPDE.jl. В работе Штепы, Беличевой и Демидовой [29] выполнено сравнение численного и нейросетевого решения модели хищник--жертва: показано, что при сопоставимом качестве решения время работы PINN (2463 с) на порядки превышает время классического метода (233 мкс).

Расширенное исследование Беличевой и соавторов [30] дополнительно включило модель SIR и уравнения Пуассона и эйконала. Для модели SIR PINN показал низкую точность, тогда как для УЧП (уравнение Пуассона) результат оказался хорошим (ошибка менее 0.009). Авторы также выявили ряд практических ограничений пакета NeuralPDE.jl: несовместимость с некоторыми стандартными функциями Julia, высокие требования к памяти и значительное число зависимостей.

Демидова и соавторы [31] разработали символьно-численный подход к исследованию кинетических моделей, а Васильева и соавторы [32] исследовали стохастические модели двух конкурентов с учётом миграции.

Выводы по главе

Проведённый обзор литературы позволяет сформулировать следующие выводы:

1. Модель межвидовой конкуренции Лотки--Вольтерры хорошо изучена аналитически, однако применение PINN к этой модели практически не исследовано --- существующие работы группы РУДН рассматривали только модель «хищник--жертва».

2. Физически-информированные нейронные сети (PINN) представляют перспективный, но не универсальный подход: для некоторых задач (SIR-модель) метод показывает низкую точность, тогда как для уравнений в частных производных демонстрирует хорошие результаты.

3. Диффузионная модель конкуренции (система реакции--диффузии) в контексте PINN исследована недостаточно, что определяет актуальность настоящей работы.

4. Программные средства (NeuralPDE.jl) активно развиваются, но имеют практические ограничения, которые необходимо учитывать при проектировании вычислительных экспериментов.

1. Lotka A. J. Elements of Physical Biology. Baltimore: Williams; Wilkins, 1925.
2. Вольтерра В. Математическая теория борьбы за существование. Москва: Наука, 1976.
3. Братусь А. С., Новожилов А. С., Платонов А. П. Динамические системы и модели биологии. Москва: Физматлит, 2010.
4. Базыкин А. Д. Нелинейная динамика взаимодействующих популяций. Москва -- Ижевск: Институт компьютерных исследований, 2003.
5. Свирежев Ю. М., Логофет Д. О. Устойчивость биологических сообществ. Москва: Наука, 1978.
6. Murray J. D. Mathematical Biology I: An Introduction. 3rd изд. New York: Springer, 2002.
7. Murray J. D. Mathematical Biology II: Spatial Models and Biomedical Applications. 3rd изд. New York: Springer, 2003.
8. Cantrell R. S., Cosner C. Spatial Ecology via Reaction-Diffusion Equations. Chichester: Wiley, 2003.
9. Fisher R. A. The wave of advance of advantageous genes // Annals of Eugenics. 1937. Т. 7, ☒ 4. С. 355--369.
10. Turing A. M. The chemical basis of morphogenesis // Philosophical Transactions of the Royal Society of London B. 1952. Т. 237. С. 37--72.
11. Hairer E., Nørsett S. P., Wanner G. Solving Ordinary Differential Equations I: Nonstiff Problems. 2nd изд. Berlin: Springer, 1993.
12. Rackauckas C., Nie Q. DifferentialEquations.jl -- A Performant and Feature-Rich Ecosystem for Solving Differential Equations in Julia // Journal of Open Research Software. 2017. Т. 5, ☒ 1. С. 15--25.

13. Bezanson J. и др. Julia: A Fresh Approach to Numerical Computing // SIAM Review. 2017. Т. 59, ☒ 1. С. 65--98.
14. Самарский А. А., Гулин А. В. Численные методы. Москва: Наука, 1989.
15. Hornik K. Approximation capabilities of multilayer feedforward networks // Neural Networks. 1991. Т. 4, ☒ 2. С. 251--257.
16. Raissi M., Perdikaris P., Karniadakis G. E. Numerical Gaussian Processes for Time-dependent and Non-linear Partial Differential Equations // SIAM Journal on Scientific Computing. 2018. Т. 40, ☒ 1. С. A172--A198.
17. Raissi M., Perdikaris P., Karniadakis G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations // Journal of Computational Physics. 2019. Т. 378. С. 686--707.
18. Karniadakis G. E. и др. Physics-informed machine learning // Nature Reviews Physics. 2021. Т. 3, ☒ 6. С. 422--440.
19. Cuomo S. и др. Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next // Journal of Scientific Computing. 2022. Т. 92, ☒ 88.
20. Chen R. T. Q. и др. Neural Ordinary Differential Equations // Advances in Neural Information Processing Systems. 2018. Т. 31.
21. Rackauckas C. и др. Universal Differential Equations for Scientific Machine Learning // arXiv preprint. 2020.
22. Wang S., Teng Y., Perdikaris P. Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks // SIAM Journal on Scientific Computing. 2021. Т. 43, ☒ 5. С. A3055--A3081.
23. Krishnapriyan A. S. и др. Characterizing possible failure modes in physics-informed neural networks // Advances in Neural Information Processing Systems. 2021. Т. 34. С. 26548--26560.
24. Jagtap A. D., Kawaguchi K., Karniadakis G. E. Adaptive activation functions accelerate convergence in deep and physics-informed neural networks // Journal of Computational Physics. 2020. Т. 404. С. 109136.
25. Rohrhofer F. M. и др. On the Pareto Front of Physics-Informed Neural Networks // IEEE Access. 2023. Т. 11. С. 85tried--85633.
26. Banerjee A., Gupta S. K. S. Recovering Implicit Physics Model Under Real-World Constraints // ECAI 2024, Frontiers in Artificial Intelligence and Applications. 2024.

27. Zubov K. и др. NeuralPDE: Automating Physics-Informed Neural Networks (PINNs) with Error Approximations // arXiv preprint. 2021.
28. Lu L. и др. DeepXDE: A deep learning library for solving differential equations // SIAM Review. 2021. Т. 63, ☒ 1. С. 208--228.
29. Штепа К. А., Беличева Д. М., Демидова Е. А. Применение NeuralPDE.jl для решения дифференциальных уравнений // Информационно-телекоммуникационные технологии и математическое моделирование --- 2024. 2024. С. 372--376.
30. Belicheva D. M. и др. Using NeuralPDE.jl to solve differential equations // Discrete and Continuous Models and Applied Computational Science. 2025. Т. 33, ☒ 3. С. 284--298.
31. Demidova E. A. и др. Symbolic-numeric approach for the investigation of kinetic models // Discrete and Continuous Models and Applied Computational Science. 2024. Т. 32, ☒ 3. С. 306--318.
32. Vasilyeva I. I., Demidova A. V., Druzhinina O. V. Computer research of deterministic and stochastic models <<two competitors -- two migration areas>> taking into account the variability of parameters // Discrete and Continuous Models and Applied Computational Science. 2024.