Сравнительное исследование численных и нейросетевых методов моделирования динамики конкурирующих популяций

Коннова Т.

2027-01-01

Содержание

Введение **4**

1. Математическое моделирование популяционной динамики и методы решения **6**
1.1. Классические модели популяционной динамики 6
1.1.1. Истоки математической экологии 6
1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры 7
1.1.3. Режимы конкуренции 7
1.2. Пространственные модели: реакция--диффузия 8
1.2.1. От ОДУ к уравнениям в частных производных 8
1.2.2. Диффузионная модель конкуренции 9
1.3. Численные методы решения 10
1.3.1. Методы решения ОДУ 10
1.3.2. Методы решения УЧП 11
1.4. Физически-информированные нейронные сети (PINN) 12
1.4.1. Предпосылки и основная идея 12
1.4.2. Обзор развития метода 13
1.4.3. Проблемы и ограничения PINN 13
1.4.4. Применение PINN к модели конкуренции 14
1.5. Программные средства решения 14
1.5.1. Библиотека NeuralPDE.jl 14
Выводы по главе 14

2. Программная реализация и вычислительные эксперименты **16**
2.1. Выбор инструментальных средств 16
2.2. Параметры вычислительных экспериментов 17
2.3. Положения равновесия и их устойчивость 17
2.4. Устойчивое сосуществование 18
2.5. Конкурентное вытеснение 18
2.6. Бистабильность 20
2.7. Предварительное решение ОДУ методом PINN 24
Выводы по этапу ОДУ 26

Список литературы **27**

Введение

Математические модели популяционной динамики связывают изменение численности видов со скоростью размножения, ограниченностью ресурсов и межвидовыми взаимодействиями. В работе рассматривается конкуренция двух популяций за общий ресурс: сначала без учёта пространства, затем с диффузионным переносом.

Классические подходы к решению систем дифференциальных уравнений, описывающих популяционную динамику, основаны на численных методах (семейство Рунге--Кутты, конечные разности). Для системы обыкновенных дифференциальных уравнений используется адаптивный метод Рунге--Кутты `Tsit5`. Пространственная модель требует дискретизации не только времени, но и координаты, поэтому число неизвестных определяется размером пространственной сетки.

В качестве второго способа решения используются физически-информированные нейронные сети (Physics-Informed Neural Networks, PINN) [1]. Дифференциальное уравнение входит в функцию потерь через невязку, вычисляемую в коллокационных точках. PINN не строит конечно-разностный шаблон, но всё равно использует дискретный набор точек для обучения.

Цель работы --- провести сравнительное исследование классических численных и нейросетевых методов решения математических моделей динамики конкурирующих популяций, включая модели с пространственной диффузией.

Задачи:

1. Исследовать математическую модель межвидовой конкуренции Лотки--Вольтерры (система ОДУ) и её расширение с учётом пространственной диффузии (система УЧП).
2. Реализовать численное решение моделей классическими методами на языке Julia с использованием библиотеки DifferentialEquations.jl.

3. Реализовать решение тех же моделей с помощью PINN на основе библиотеки NeuralPDE.jl.
4. Провести сравнительный анализ точности, вычислительных затрат и устойчивости обоих подходов.
5. Исследовать влияние параметров нейросетевой архитектуры на качество решения.

Объект исследования --- математические модели конкурирующих популяций.

Предмет исследования --- численные и нейросетевые методы решения систем обыкновенных дифференциальных уравнений и уравнений в частных производных, описывающих динамику конкурирующих популяций.

Сравнение методов проводится при одинаковых параметрах модели и начальных условиях. Оцениваются средняя и максимальная абсолютные ошибки относительно классического решения, время вычислений, сохранение неотрицательности численностей и воспроизводимость результата при разных инициализациях нейронной сети.

1. Математическое моделирование популяционной динамики и методы решения

1.1. Классические модели популяционной динамики

1.1.1. Истоки математической экологии

Математическое описание динамики биологических популяций берёт начало в работах А. Лотки [2] и В. Вольтерры [3], которые независимо друг от друга в 1920-х годах предложили системы обыкновенных дифференциальных уравнений для описания взаимодействия двух видов. Модель «хищник--жертва» Лотки--Вольтерры стала одной из ранних математических формализаций экологических взаимодействий и послужила основой для последующих моделей взаимодействующих популяций.

Классическая модель хищник--жертва имеет вид:

$$\begin{cases} \dfrac{dx}{dt} = \alpha x - \beta xy, \\ \dfrac{dy}{dt} = -\gamma y + \delta xy, \end{cases} \tag{1.1}$$

где $x(t)$ --- численность жертв, $y(t)$ --- численность хищников, $\alpha, \beta, \gamma, \delta > 0$ --- параметры модели. Решения этой системы обладают периодическим характером, а фазовые траектории образуют замкнутые кривые вокруг внутренней неподвижной точки. Система допускает первый интеграл $\alpha \ln y - \beta y + \gamma \ln x - \delta x = C$, что позволяет верифицировать численные решения [4].

В монографии А. Д. Базыкина [5] систематизированы бифуркационные явления в нелинейных моделях взаимодействующих популяций. Ю. М. Свирежев и Д. О. Логофет [6] исследовали вопросы устойчивости биологических сообществ на основе качественной теории дифференциальных уравнений. Фундаментальная двухтомная монография Дж. Мюррея [7,8] является одним из наиболее полных изложений методов математической биологии, включая пространственные модели.

1.1.2. Модель межвидовой конкуренции Лотки--Вольтерры

В отличие от модели «хищник--жертва», где один вид потребляет другой, модель межвидовой конкуренции описывает ситуацию, когда два вида борются за общий ограниченный ресурс. Каждый вид подчиняется логистическому закону роста, а присутствие конкурента снижает доступность ресурса. Модель записывается в виде системы ОДУ [4,7]:

$$\begin{cases} \dfrac{dN_1}{dt} = r_1 N_1 \left(1 - \dfrac{N_1 + \alpha_{12} N_2}{K_1}\right), \\ \dfrac{dN_2}{dt} = r_2 N_2 \left(1 - \dfrac{N_2 + \alpha_{21} N_1}{K_2}\right), \end{cases} \tag{1.2}$$

где $N_i(t)$ --- численность i-го вида, r_i --- скорость естественного прироста, K_i --- ёмкость среды (максимальная численность при отсутствии конкурента), α_{12} и α_{21} --- коэффициенты межвидовой конкуренции.

Коэффициент α_{12} показывает, насколько одна особь вида 2 эквивалентна особи вида 1 в потреблении ресурса. При $\alpha_{12} = 0$ виды не конкурируют, при $\alpha_{12} = 1$ одна особь конкурента эквивалентна одной собственной особи.

1.1.3. Режимы конкуренции

Система (Уравнение 1.2) имеет четыре стационарные точки: $E_0 = (0, 0)$, $E_1 = (K_1, 0)$, $E_2 = (0, K_2)$ и внутреннюю точку сосуществования

$$E^* = \left(\frac{K_1 - \alpha_{12} K_2}{1 - \alpha_{12}\alpha_{21}},\ \frac{K_2 - \alpha_{21} K_1}{1 - \alpha_{12}\alpha_{21}}\right),$$

которая существует (обе координаты положительны) лишь при определённых соотношениях параметров. Анализ устойчивости этих точек приводит к классификации трёх качественно различных режимов динамики [5,7]:

1. **Устойчивое сосуществование** ($\alpha_{12} < K_1/K_2$ и $\alpha_{21} < K_2/K_1$). Межвидовая конкуренция слабее внутривидовой. Точка E^* существует и является устойчивым узлом; оба вида сохраняют ненулевую численность. При $K_1 = K_2$ условия принимают вид $\alpha_{12} < 1$ и $\alpha_{21} < 1$; неравенство $\alpha_{12}\alpha_{21} < 1$ является следствием этих условий, но не заменяет их.

2. **Конкурентное вытеснение** ($\alpha_{12} > K_1/K_2$ и $\alpha_{21} < K_2/K_1$, или наоборот). Один из видов вытесняет другой независимо от начальных условий. Устойчивой является одна из граничных точек (E_1 или E_2). Данный результат известен как *принцип конкурентного исключения Гаузе*.

3. **Бистабильность** ($\alpha_{12} > K_1/K_2$ и $\alpha_{21} > K_2/K_1$). Межвидовая конкуренция сильнее внутривидовой. Точки E_1 и E_2 обе устойчивы, а E^* --- седловая точка. Исход зависит от начальных условий: сепаратриса седловой точки разделяет области притяжения двух устойчивых состояний. При $K_1 = K_2$ требуются одновременно $\alpha_{12} > 1$ и $\alpha_{21} > 1$; одного условия $\alpha_{12}\alpha_{21} > 1$ недостаточно.

Классификация режимов следует из анализа существования и устойчивости стационарных точек [4,7]. В отличие от консервативной модели хищник--жертва (Уравнение 1.1), траектории рассматриваемой модели конкуренции в типичных режимах стремятся к стационарным состояниям. Поэтому первый интеграл модели хищник--жертва нельзя использовать для проверки решения системы конкуренции.

1.2. Пространственные модели: реакция--диффузия

1.2.1. От ОДУ к уравнениям в частных производных

Классические модели вида (Уравнение 1.2) предполагают пространственно однородное распределение популяций. В реальных экосистемах особи перемещаются в пространстве, и плотность популяции $N_i(t, x)$ зависит не

только от времени t, но и от пространственной координаты x. Переход к пространственным моделям осуществляется добавлением диффузионных членов, описывающих случайное (броуновское) движение особей [8,9].

Механизм диффузии формализуется законом Фика: поток особей пропорционален градиенту плотности и направлен из областей высокой концентрации в области низкой. Для одномерного случая это приводит к диффузионному оператору $D\partial^2 N/\partial x^2$, где вторая производная по пространству характеризует кривизну профиля плотности: при локальном максиме ($\partial^2 N/\partial x^2 < 0$) особи расходятся, при локальном минимуме ($\partial^2 N/\partial x^2 > 0$) --- стекаются.

Пионерские работы в области реакционно-диффузионных уравнений принадлежат Р. Фишеру [10], предложившему уравнение распространения выгодного гена:

$$\frac{\partial u}{\partial t} = D\frac{\partial^2 u}{\partial x^2} + ru(1-u), \tag{1.3}$$

являющееся простейшим примером уравнения реакции--диффузии, допускающим решения в виде бегущих волн. А. Тьюринг [11] показал, что в некоторых многокомпонентных системах реакция--диффузия однородное стационарное состояние может потерять устойчивость после добавления диффузии. Однако этот результат нельзя автоматически переносить на любую экологическую модель. Для рассматриваемой ниже системы конкуренции с постоянными коэффициентами и обычной собственной диффузией наличие тьюринговской неустойчивости должно проверяться отдельно; различие коэффициентов D_1 и D_2 само по себе не гарантирует образование паттернов.

1.2.2. Диффузионная модель конкуренции

После добавления пространственного переноса модель (Уравнение 1.2) принимает вид системы реакции--диффузии:

$$\begin{cases} \dfrac{\partial N_1}{\partial t} = D_1\dfrac{\partial^2 N_1}{\partial x^2} + r_1 N_1\left(1 - \dfrac{N_1 + \alpha_{12}N_2}{K_1}\right), \\ \dfrac{\partial N_2}{\partial t} = D_2\dfrac{\partial^2 N_2}{\partial x^2} + r_2 N_2\left(1 - \dfrac{N_2 + \alpha_{21}N_1}{K_2}\right), \end{cases} \tag{1.4}$$

где $D_i > 0$ --- коэффициенты диффузии, характеризующие интенсивность пространственного перемещения особей i-го вида. Слагаемые $D_i\partial^2 N_i/\partial x^2$

описывают перемещение особей из областей высокой концентрации в области низкой концентрации (закон Фика).

Уравнения (Уравнение 1.4) дополняются начальными условиями $N_i(x,0) = N_{i,0}(x)$ и граничными условиями. Наиболее часто используются условия Неймана (нулевой поток на границе), моделирующие замкнутую область обитания [9]:

$$\left.\frac{\partial N_i}{\partial x}\right|_{x=0} = \left.\frac{\partial N_i}{\partial x}\right|_{x=L} = 0, \quad i = 1, 2.$$

Монография Кантрелла и Коснера [9] содержит систематическое изложение теории пространственной экологии на основе уравнений реакции-диффузии, включая вопросы существования и устойчивости стационарных решений. Устойчивые пространственно неоднородные состояния в моделях конкуренции зависят от постановки задачи: гетерогенности среды, граничных условий, структуры диффузии и параметров взаимодействия [12].

При пространственно однородных начальных условиях и нулевом потоке система (Уравнение 1.4) воспроизводит соответствующую ОДУ-модель. Неоднородные начальные данные добавляют переходные пространственные процессы. В частности, при различных начальных распределениях $N_{1,0}(x)$ и $N_{2,0}(x)$ (например, один вид локализован слева, другой --- справа) динамика включает фазу диффузионного проникновения видов на территорию конкурента, что качественно отличается от ODE-случая. В вычислительной части такие сценарии используются для сравнения численного и нейросетевого решений.

1.3. Численные методы решения

1.3.1. Методы решения ОДУ

Для численного решения систем ОДУ вида (Уравнение 1.2) широко применяются методы семейства Рунге--Кутты [13]. Метод Цитораса (`Tsit5`) относится к явным методам Рунге--Кутты 5(4) порядка. Встроенная формула четвёртого порядка служит для оценки локальной ошибки и выбора следующего шага. Реализация `Tsit5` входит в экосистему DifferentialEquations.jl [14] для языка Julia [15].

Для жёстких систем применяются неявные методы (Розенброка, BDF), также доступные в DifferentialEquations.jl. Экосистема DifferentialEquations.jl предоставляет унифицированный интерфейс для явных и неявных методов, средства автоматического выбора алгоритма и анализа чувствительности [14].

1.3.2. Методы решения УЧП

Классическим подходом к решению систем реакции--диффузии (Уравнение 1.4) является метод конечных разностей [16]. Пространственная производная аппроксимируется на равномерной сетке:

$$\frac{\partial^2 N}{\partial x^2} \approx \frac{N_{j-1} - 2N_j + N_{j+1}}{(\Delta x)^2},$$

после чего система УЧП сводится к системе ОДУ (метод прямых, method of lines), которая решается стандартными методами.

На сетке с n узлами по каждой координате число пространственных неизвестных пропорционально n^d, где d --- размерность пространства. Поэтому переход от одномерной области к двумерной или трёхмерной увеличивает объём системы. Для явной аппроксимации диффузии шаг по времени дополнительно ограничен условием устойчивости вида $\Delta t \leq C(\Delta x)^2/D$; уменьшение Δx требует уменьшать и Δt. Неявные схемы снимают ограничение на шаг, но требуют решения систем линейных уравнений на каждом временном слое.

Альтернативой конечным разностям являются конечные элементы и спектральные методы, однако их реализация существенно сложнее. Метод прямых, сводящий систему УЧП к большой системе ОДУ, позволяет использовать адаптивные солверы ОДУ (включая Tsit5) и является основным подходом, реализованным в DifferentialEquations.jl [14].

1.4. Физически-информированные нейронные сети (PINN)

1.4.1. Предпосылки и основная идея

Возможность аппроксимации произвольных непрерывных функций нейронными сетями обоснована теоремой об универсальной аппроксимации [17]: для любой непрерывной функции и заданной точности $\varepsilon > 0$ существует нейронная сеть с одним скрытым слоем, аппроксимирующая эту функцию с точностью ε.

В методе PINN дифференциальное уравнение включается в функцию потерь нейронной сети [1]. Нейросеть $N(x; w)$ с параметрами (весами) w обучается аппроксимировать неизвестное решение $u(x)$ дифференциального уравнения $F(u(x); \lambda) = 0$ путём минимизации составной функции потерь:

$$L(w) = L_r + L_{ic} + L_{bc}, \tag{1.5}$$

где:

- $L_r = \sum_i \|F(N(x_i; w); \lambda)\|^2$ --- невязка дифференциального уравнения в коллокационных точках x_i (residual loss);
- $L_{ic} = \sum_j \|N(x_j; w) - u_0(x_j)\|^2$ --- отклонение от начальных условий;
- $L_{bc} = \sum_k \|B(N(x_k; w))\|^2$ --- отклонение от граничных условий.

Производные нейросети N по входным переменным вычисляются с помощью автоматического дифференцирования, а не конечно-разностной аппроксимации. При этом точность итогового решения определяется не только вычислением производных, но и архитектурой сети, набором коллокационных точек и результатом оптимизации.

Теорема об универсальной аппроксимации обосновывает выразительность нейронной сети, но не гарантирует успешной оптимизации PINN, малой ошибки решения или выполнения начальных и граничных условий.

1.4.2. Обзор развития метода

Обзорная статья Karniadakis и соавторов [18] в Nature Reviews Physics систематизировала направление «physics-informed machine learning» и выделила PINN как один из центральных инструментов. Масштабный обзор Cuomo и соавторов [19] проанализировал более 200 работ по PINN, классифицировал архитектуры, стратегии обучения и области применения.

Chen и соавторы [20] предложили концепцию Neural ODE --- представление динамической системы как непрерывного аналога глубокой нейросети, что привело к созданию нового класса моделей на стыке машинного обучения и дифференциальных уравнений. Rackauckas и соавторы [21] развили эту идею в концепцию Universal Differential Equations (UDE), где часть дифференциального оператора заменяется нейросетью, обучаемой по данным.

1.4.3. Проблемы и ограничения PINN

Обучение PINN сводится к невыпуклой задаче оптимизации, поэтому малая невязка на обучающих точках сама по себе не гарантирует малую ошибку решения во всей области.

Wang, Teng и Perdikaris [22] исследовали проблемы градиентных потоков при обучении PINN и показали, что разные компоненты функции потерь (Уравнение 1.5) могут конфликтовать, приводя к дисбалансу обучения. Авторы предложили адаптивное взвешивание компонент loss-функции для повышения сходимости.

Krishnapriyan и соавторы [23] систематически изучили возможные режимы отказа PINN и показали, что для систем с колебательной динамикой и длинными временными интервалами PINN испытывают трудности с аппроксимацией.

Jagtap, Kawaguchi и Karniadakis [24] предложили адаптивные функции активации, ускоряющие сходимость PINN.

Rohrhofer и соавторы [25] исследовали компромисс между точностью выполнения уравнений и соответствием данным, построив парето-фронт для различных конфигураций PINN.

1.4.4. Применение PINN к модели конкуренции

Для системы конкуренции нейронная сеть должна одновременно аппроксимировать две неотрицательные функции численности. В задаче с диффузией к двум невязкам уравнений добавляются начальные и граничные условия. Их вклады в функцию потерь могут иметь разные масштабы, поэтому качество решения проверяется не только по значению loss-функции, но и прямым сравнением с классическим численным методом.

Сначала это сравнение выполняется для ОДУ на трёх режимах динамики: сосуществовании, вытеснении и бистабильности. Затем тот же порядок применяется к пространственной модели. Такой переход позволяет отдельно проверить ошибку нейросетевой аппроксимации и влияние пространственных производных.

1.5. Программные средства решения

1.5.1. Библиотека NeuralPDE.jl

Библиотека NeuralPDE.jl [26] входит в экосистему SciML и предоставляет высокоуровневый интерфейс для решения ОДУ и УЧП с помощью PINN на языке Julia. Для систем ОДУ алгоритм `NNODE` работает со стандартным объектом `ODEProblem` и функцией правой части, записанной во вневекторизованной форме `f(u,p,t)` [27]. Для систем УЧП `PhysicsInformedNN` преобразует символьное описание `PDESystem`, построенное средствами ModelingToolkit.jl, в задачу оптимизации [28]. Архитектура нейронной сети в обоих случаях может задаваться с помощью Lux.jl.

Выводы по главе

1. Аналитическая классификация модели конкуренции задаёт три контрольных режима и ожидаемые стационарные состояния для проверки программной реализации.
2. Для ОДУ эталонное решение строится методом `Tsit5`; для системы реакции--диффузии используется пространственная дискретизация с последующим интегрированием по времени.

3. Результат PINN необходимо сравнивать с эталонным решением по ошибке во всей расчётной области. Это особенно существенно для длинных временных интервалов и составной функции потерь [22,23].

2. Программная реализация и вычислительные эксперименты

В главе представлена программная реализация классической модели межвидовой конкуренции, результаты ноябрьского этапа и предварительный эксперимент PINN для системы обыкновенных дифференциальных уравнений. Пространственная модель будет исследована на следующих этапах работы.

2.1. Выбор инструментальных средств

Расчёты выполнены на языке Julia с применением библиотеки OrdinaryDiffEq.jl. Для интегрирования системы используется явный адаптивный метод Рунге--Кутты Цитораса `Tsit5` порядка 5(4). Графики построены средствами Plots.jl. Исходный код эксперимента находится в файле `code/ode/competition_model.jl`.

Вычислительный эксперимент включает:

1. автоматическую классификацию режима по двум пороговым неравенствам;
2. вычисление аналитических положений равновесия;
3. оценку устойчивости равновесий по собственным значениям матрицы Якоби;
4. численное решение для нескольких начальных условий;
5. проверку неотрицательности решения и сходимости к теоретически ожидаемому равновесию;
6. построение временных графиков и фазовых портретов.

2.2. Параметры вычислительных экспериментов

Для трёх режимов использованы наборы параметров, приведённые в таблице Таблица 2.1. Скорости роста во всех экспериментах равны $r_1 = r_2 = 1$.

Таблица 2.1.: Параметры трёх режимов конкуренции

Режим	K_1	K_2	α_{12}	α_{21}	Ожидаемый предел
Сосуществование	100	100	0,5	0,3	E^*
Вытеснение	100	80	0,4	1,5	E_1
Бистабильность	100	100	1,5	1,5	E_1 или E_2

Условия режимов проверяются отдельно для каждого коэффициента. Для сосуществования необходимы неравенства $\alpha_{12} < K_1/K_2$ и $\alpha_{21} < K_2/K_1$. Для бистабильности направления обоих неравенств меняются на противоположные. Условие только на произведение $\alpha_{12}\alpha_{21}$ не используется как достаточный критерий.

2.3. Положения равновесия и их устойчивость

Матрица Якоби системы вычисляется в каждой аналитической стационарной точке. Точка считается устойчивой, если действительные части обоих собственных значений отрицательны. Если собственные значения имеют действительные части разных знаков, равновесие является седловым.

Таблица 2.2.: Результаты анализа устойчивости равновесий

Режим	Устойчивые равновесия	Неустойчивые и седловые точки
Сосуществование	$E^* = (58{,}8235;\ 82{,}3529)$	E_0 неустойчиво; E_1 и E_2 --- седла
Вытеснение	$E_1 = (100;\ 0)$	E_0 неустойчиво; $E_2 = (0;\ 80)$ --- седло
Бистабильность	$E_1 = (100;\ 0)$ и $E_2 = (0;\ 100)$	E_0 неустойчиво; $E^* = (40;\ 40)$ --- седло

2.4. Устойчивое сосуществование

Для всех четырёх проверенных начальных условий численное решение сходится к одной внутренней точке $E^* = (58{,}8235;\ 82{,}3529)$. Максимальное расстояние между конечным состоянием при $t = 30$ и аналитическим равновесием среди рассмотренных траекторий не превышает $7{,}3 \cdot 10^{-4}$.

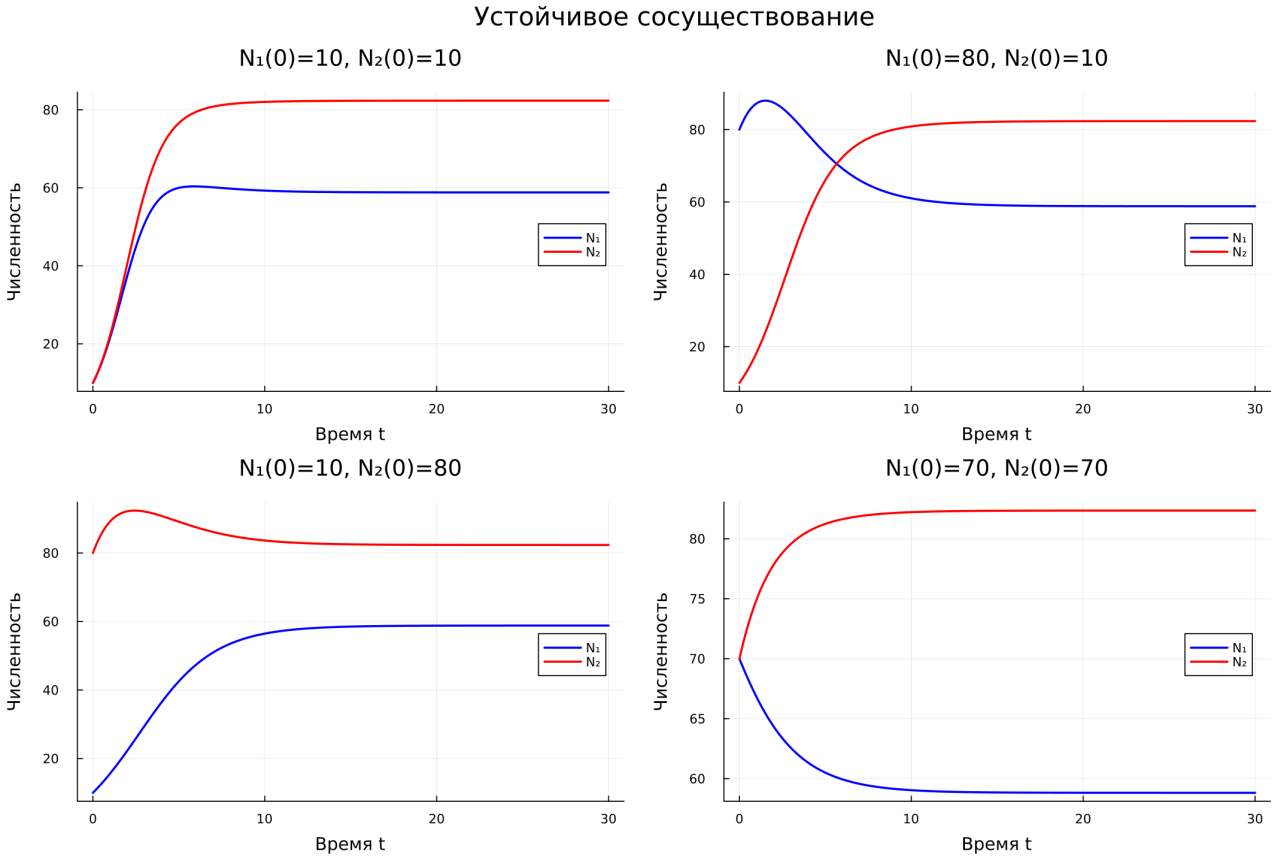


Рис. 2.1.: Динамика численностей в режиме устойчивого сосуществования

Фазовый портрет на рисунке Рисунок 2.2 показывает, что траектории из различных частей положительного квадранта сходятся к одной устойчивой внутренней точке.

2.5. Конкурентное вытеснение

При $\alpha_{12} = 0{,}4$ и $\alpha_{21} = 1{,}5$ устойчивой является граничная точка $E_1 = (100;\ 0)$. Во всех четырёх экспериментах, включая начальное условие

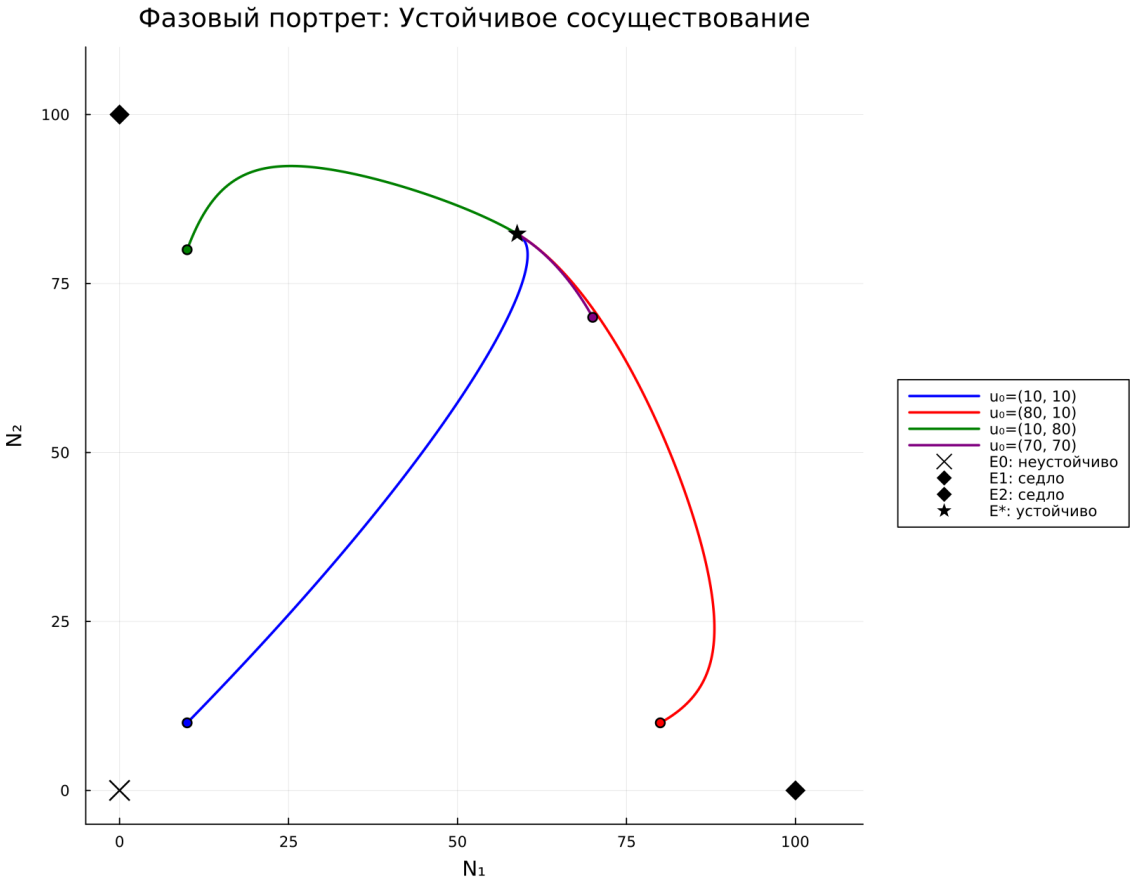


Рис. 2.2.: Фазовый портрет режима устойчивого сосуществования

$N_1(0) = 20$, $N_2(0) = 70$, первый вид вытесняет второй. Численный результат совпадает с теоретическим прогнозом и не зависит от выбранного положительного начального условия.

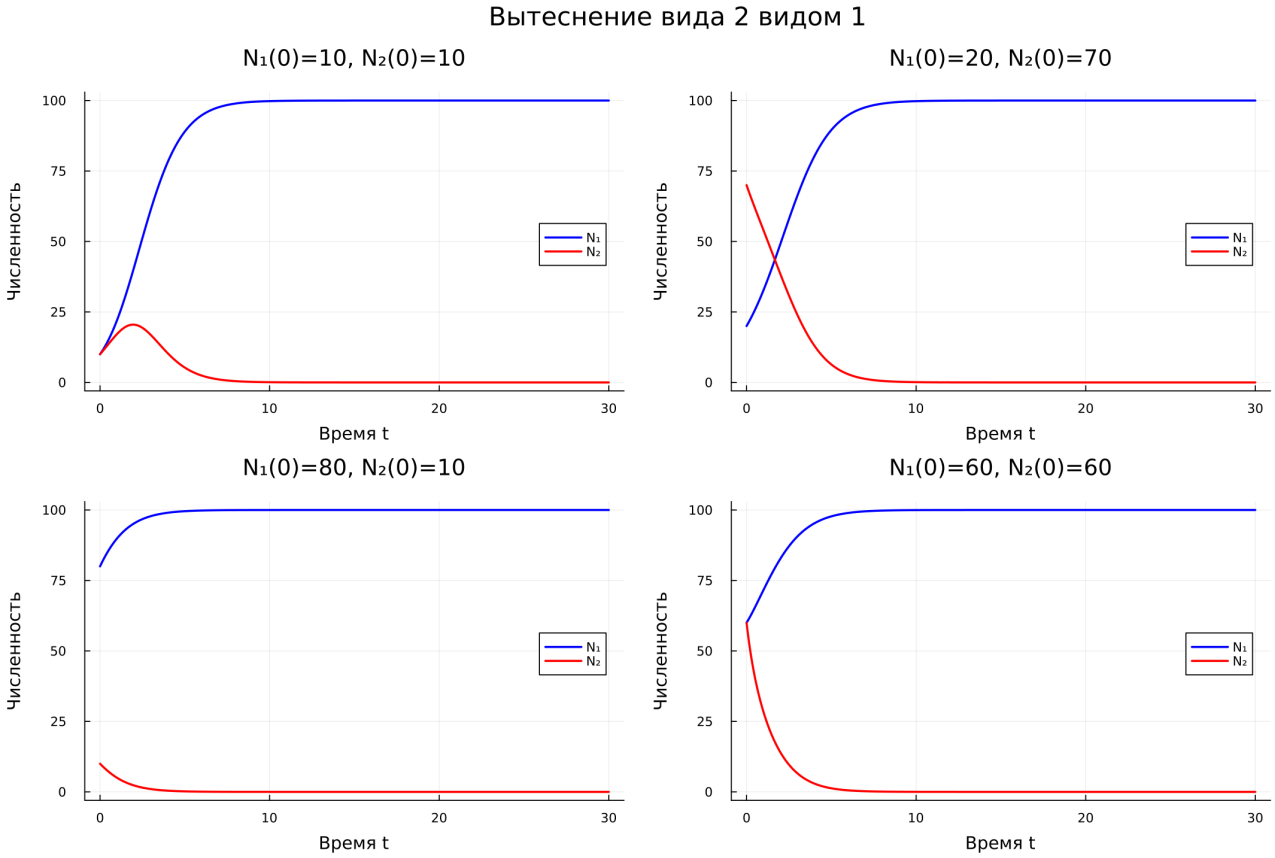


Рис. 2.3.: Динамика численностей в режиме вытеснения

2.6. Бистабильность

В симметричном случае $K_1 = K_2 = 100$ и $\alpha_{12} = \alpha_{21} = 1{,}5$ граничные точки E_1 и E_2 устойчивы, а внутренняя точка $E^* = (40;\ 40)$ является седлом. Начальные условия $(80; 20)$ и $(65; 35)$ приводят к равновесию E_1, тогда как условия $(20; 80)$ и $(35; 65)$ приводят к E_2.

В выбранном симметричном примере сепаратрисой является прямая $N_1 = N_2$. Она разделяет области притяжения двух устойчивых граничных равновесий. Это частный симметричный случай: для произвольных параметров сепаратриса не обязана совпадать с прямой равных численностей.

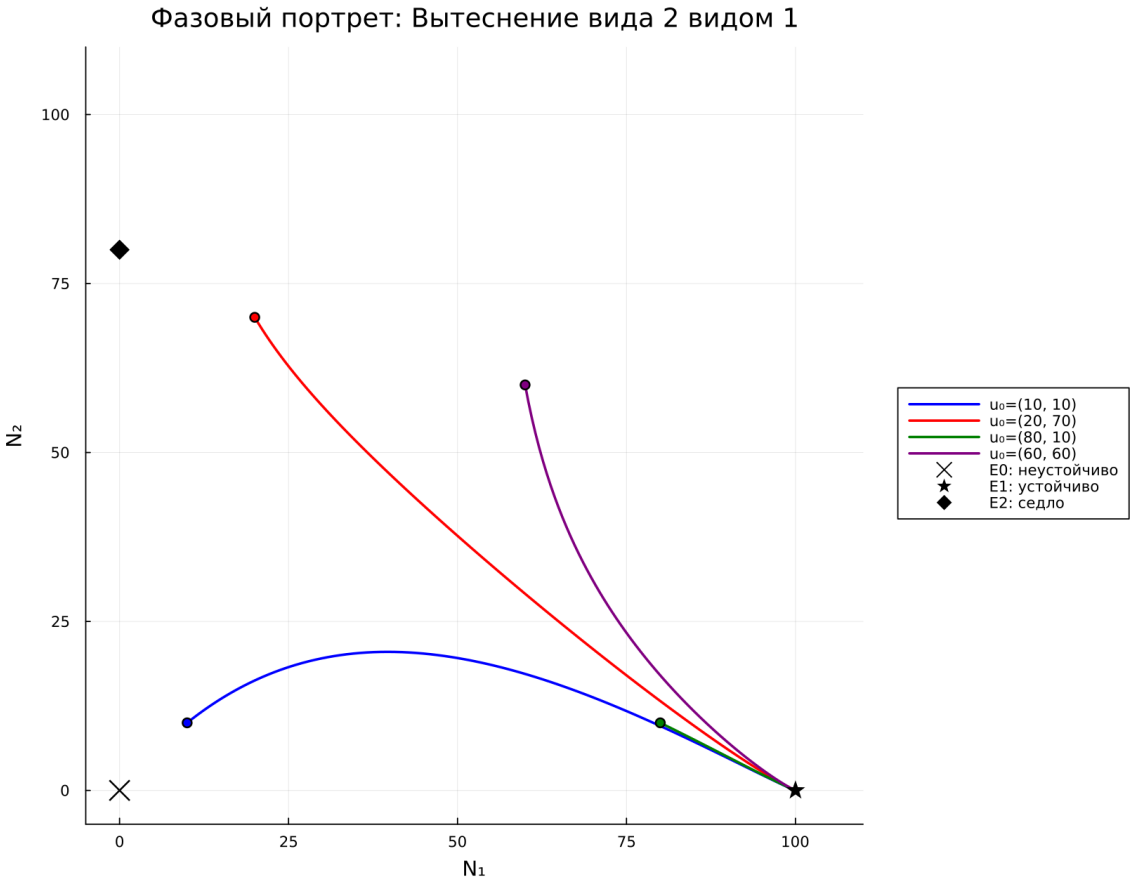


Рис. 2.4.: Фазовый портрет режима вытеснения

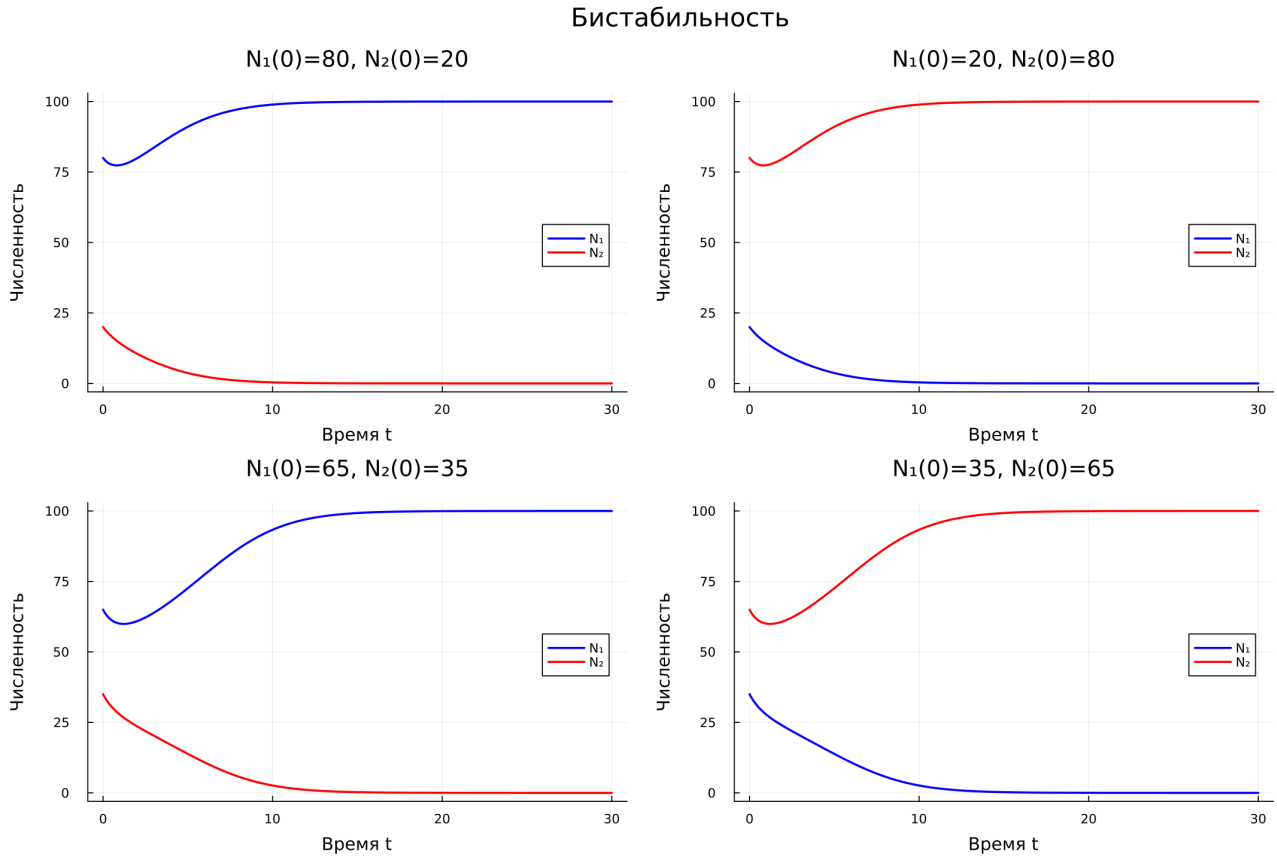


Рис. 2.5.: Динамика численностей в режиме бистабильности

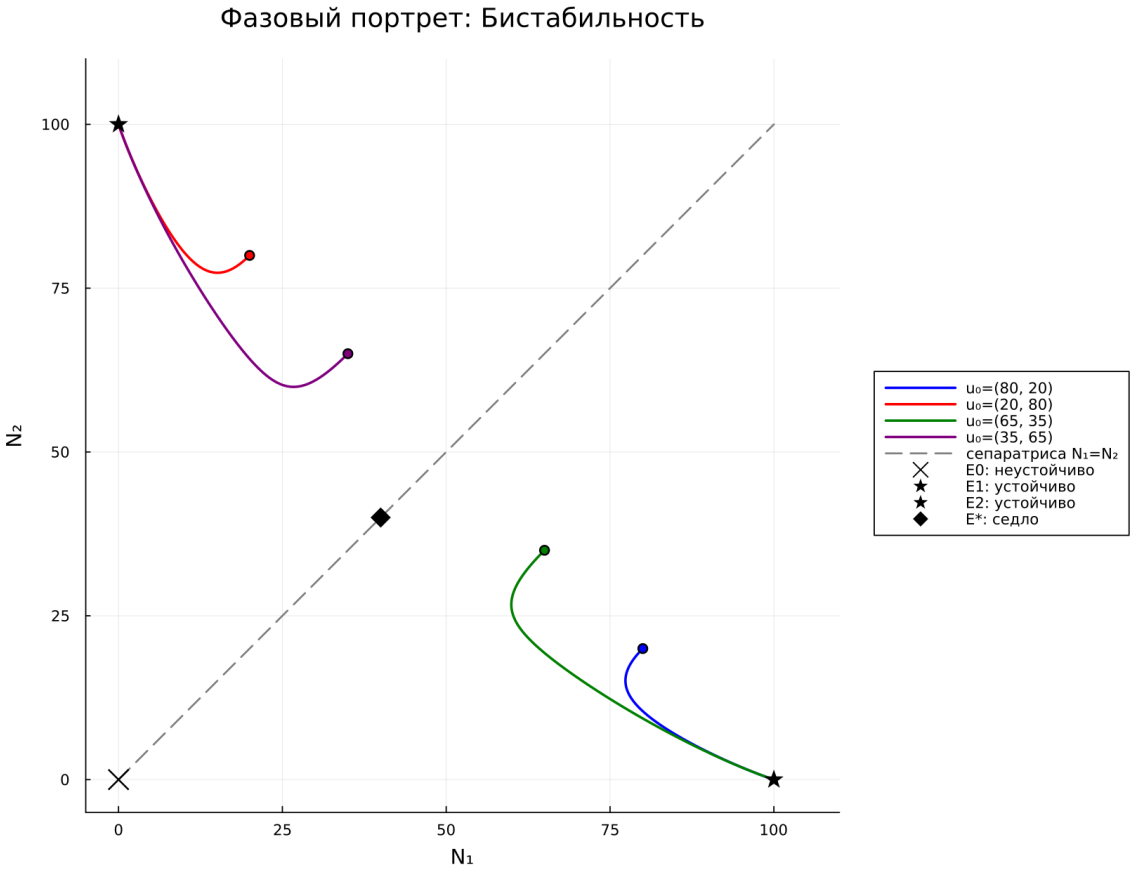


Рис. 2.6.: Фазовый портрет режима бистабильности

2.7. Предварительное решение ОДУ методом PINN

Для нейросетевого решения использован алгоритм `NNODE` библиотеки NeuralPDE.jl [27]. Начальное условие в этой реализации включается в аппроксимацию решения, а обучение минимизирует невязку нормализованной системы ОДУ. Нормализация задана формулами

$$u_1 = \frac{N_1}{K_1}, \qquad u_2 = \frac{N_2}{K_2}, \qquad \tau = r_1 t.$$

Использована полносвязная сеть с четырьмя скрытыми слоями по 64 нейрона и функцией активации `gelu`. Оптимизация выполнена методом Adam с шагом 0,01 в течение 1000 итераций. Интервал $\tau \in [0; 5]$ разбит интервальной стратегией обучения с весами $(0{,}7; 0{,}2; 0{,}1)$. Эталоном служит решение `Tsit5` в 101 точке с шагом сохранения 0,05.

Для оценки зависимости от случайной инициализации проведены запуски с `seed` 11, 42 и 73. В таблице Таблица 2.3 приведены усреднённые абсолютные ошибки в исходных единицах численности. Последние два столбца содержат наибольшую точечную ошибку среди всех трёх запусков.

Таблица 2.3.: Ошибки PINN относительно Tsit5 на интервале $[0; 5]$

Режим	Средняя MAE N_1	Средняя MAE N_2	Наибольшая Max N_1	Наибольшая Max N_2
Сосуществование	0,0964	0,0847	0,3944	0,7067
Вытеснение	0,4175	0,1589	2,0354	1,1307
Бистабильность	0,1271	0,0990	0,8209	0,3603

Во всех девяти основных запусках число отрицательных значений, меньших $-0{,}01$, равно нулю. Наибольшая зависимость от инициализации обнаружена для режима вытеснения: при `seed = 73` средняя ошибка N_1 составила 1,174, тогда как при двух других инициализациях она не превышала 0,07. Поэтому единичный успешный запуск нельзя считать достаточным подтверждением качества PINN.

Дополнительные проверки выполнены для начального условия $(70; 20)$ в режиме сосуществования и $(20; 80)$ в режиме бистабильности. В первом случае MAE равны 0,085 и 0,219, во втором --- 0,121 и 0,159. Тем самым

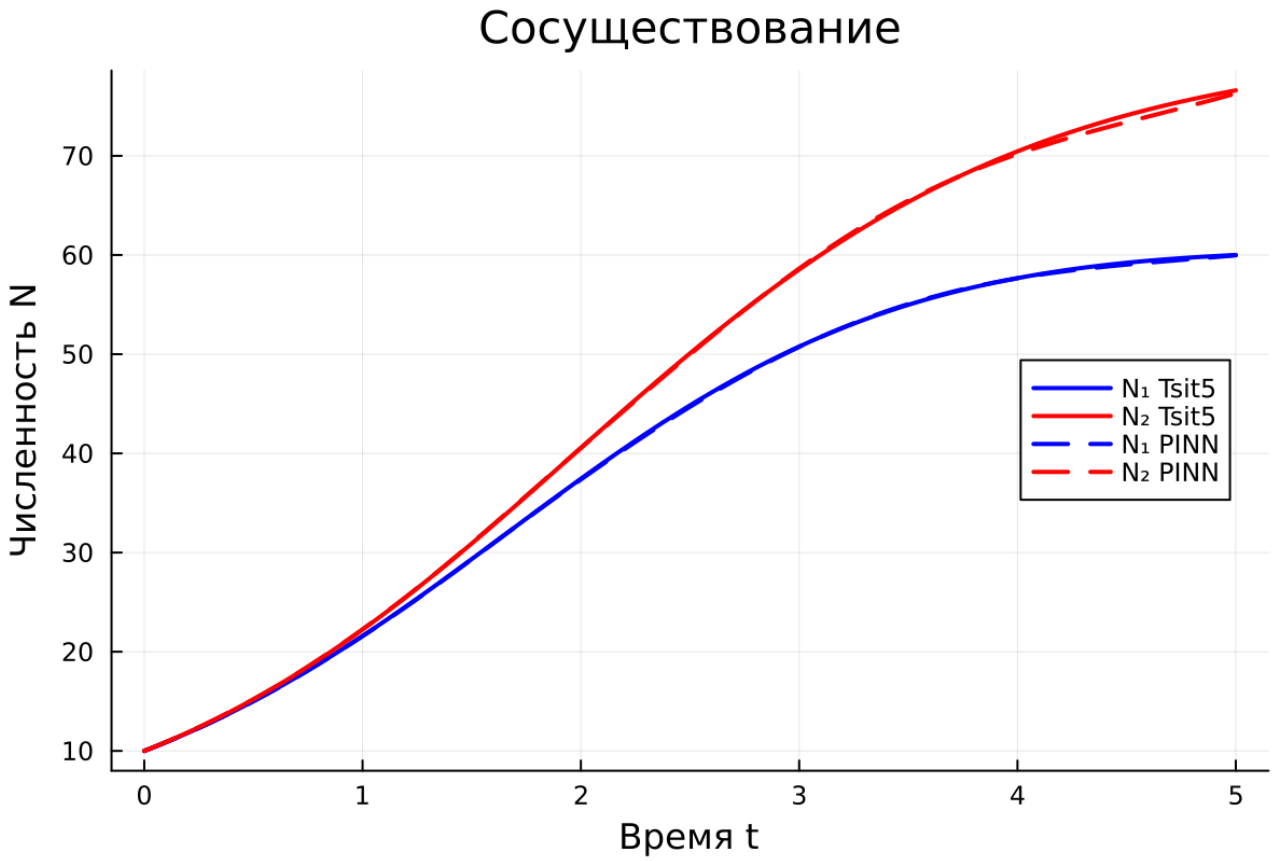


Рис. 2.7.: PINN и Tsit5 в режиме сосуществования

проверены обе области притяжения симметричного бистабильного режима.

Среднее время уже прогретого `Tsit5` составило менее 10^{-4} с, тогда как обучение PINN занимало примерно 19--47 с в зависимости от режима и включало компиляцию нейросетевого решателя в каждом отдельном процессе. Эти значения показывают вычислительные затраты текущей реализации, но не являются строгим аппаратно-независимым бенчмарком.

Выводы по этапу ОДУ

Решения `Tsit5` для трёх режимов сохраняют неотрицательность численностей и сходятся к равновесиям, найденным при аналитическом исследовании. На интервале $[0; 5]$ решение `NNODE` близко к `Tsit5`, но ошибки различаются при смене случайной инициализации сети, а обучение занимает на несколько порядков больше времени. Эти результаты относятся только к проверенному интервалу: для итогового сравнения нужны расчёты до $t = 15$--20 и единый протокол измерения времени.

Список литературы

1. Raissi M., Perdikaris P., Karniadakis G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations // Journal of Computational Physics. 2019. Т. 378. С. 686--707.
2. Lotka A. J. Elements of Physical Biology. Baltimore: Williams; Wilkins, 1925. С. 460.
3. Вольтерра В. Математическая теория борьбы за существование. Москва: Наука, 1976. С. 286.
4. Братусь А. С., Новожилов А. С., Платонов А. П. Динамические системы и модели биологии. Москва: Физматлит, 2010. С. 400.
5. Базыкин А. Д. Нелинейная динамика взаимодействующих популяций. Ижевск: Институт компьютерных исследований, 2003. С. 368.
6. Свирежев Ю. М., Логофет Д. О. Устойчивость биологических сообществ. Москва: Наука, 1978. С. 352.
7. Murray J. D. Mathematical Biology I: An Introduction. 3rd изд. New York: Springer, 2002.
8. Murray J. D. Mathematical Biology II: Spatial Models and Biomedical Applications. 3rd изд. New York: Springer, 2003.
9. Cantrell R. S., Cosner C. Spatial Ecology via Reaction-Diffusion Equations. Chichester: Wiley, 2003. С. 432.
10. Fisher R. A. The wave of advance of advantageous genes // Annals of Eugenics. 1937. Т. 7, No. 4. С. 355--369.
11. Turing A. M. The chemical basis of morphogenesis // Philosophical Transactions of the Royal Society of London B. 1952. Т. 237. С. 37--72.
12. Cosner C., Lazer A. C. Stable Coexistence States in the Volterra--Lotka Competition Model with Diffusion // SIAM Journal on Applied Mathematics. 1984. Т. 44, No. 6. С. 1112--1132.
13. Hairer E., Nørsett S. P., Wanner G. Solving Ordinary Differential Equations I: Nonstiff Problems. 2nd изд. Berlin: Springer, 1993.

14. Rackauckas C., Nie Q. DifferentialEquations.jl -- A Performant and Feature-Rich Ecosystem for Solving Differential Equations in Julia // Journal of Open Research Software. 2017. Т. 5, No. 1. С. 15--25.
15. Bezanson J. и др. Julia: A Fresh Approach to Numerical Computing // SIAM Review. 2017. Т. 59, No. 1. С. 65--98.
16. Самарский А. А., Гулин А. В. Численные методы. Москва: Наука, 1989. С. 432.
17. Hornik K. Approximation capabilities of multilayer feedforward networks // Neural Networks. 1991. Т. 4, No. 2. С. 251--257.
18. Karniadakis G. E. и др. Physics-informed machine learning // Nature Reviews Physics. 2021. Т. 3, No. 6. С. 422--440.
19. Cuomo S. и др. Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next // Journal of Scientific Computing. 2022. Т. 92, No. 88.
20. Chen R. T. Q. и др. Neural Ordinary Differential Equations // Advances in Neural Information Processing Systems. 2018. Т. 31.
21. Rackauckas C. и др. Universal Differential Equations for Scientific Machine Learning // arXiv preprint. 2020.
22. Wang S., Teng Y., Perdikaris P. Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks // SIAM Journal on Scientific Computing. 2021. Т. 43, No. 5. С. A3055--A3081.
23. Krishnapriyan A. S. и др. Characterizing possible failure modes in physics-informed neural networks // Advances in Neural Information Processing Systems. 2021. Т. 34. С. 26548--26560.
24. Jagtap A. D., Kawaguchi K., Karniadakis G. E. Adaptive activation functions accelerate convergence in deep and physics-informed neural networks // Journal of Computational Physics. 2020. Т. 404. С. 109136.
25. Rohrhofer F. M. и др. On the Pareto Front of Physics-Informed Neural Networks // IEEE Access. 2023. Т. 11. С. 85613--85633.
26. Zubov K. и др. NeuralPDE: Automating Physics-Informed Neural Networks (PINNs) with Error Approximations // arXiv preprint. 2021.
27. SciML. ODE-Specialized Physics-Informed Neural Network Solver [Электронный ресурс]. 2026. URL: https://docs.sciml.ai/NeuralPDE/stable/manual/ode/ (дата обращения: 08.11.2026).
28. SciML. PhysicsInformedNN Discretizer for PDESystems [Электронный ресурс]. 2026. URL: https://docs.sciml.ai/NeuralPDE/stable/manual/pinns/ (дата обращения: 08.11.2026).